

CHALLENGE CLARO

ClaroIntelligence

Arquitetura final da solução e funcionalidades do protótipo

Entrega Sprint 3

Camada de orquestração com inteligência artificial sobre os canais digitais e sobre o portfólio multiproduto da Claro. O documento apresenta a arquitetura final da solução em dois diagramas, explica as funcionalidades entregues no protótipo funcional e indica o vídeo de demonstração.

Vídeo de demonstração:

<https://youtu.be/NAFeMhycqoE>

Equipe:

RM98845 - Rafael Jun Miura

RM97826 - Guilherme Korus Daoud

RM98561 - Marcos Henrique Ribeiro de Santana

RM99949 - Raphael Oliveira Batizati

RM98577 - Sergio Nogueira dos Santos

Sumário

1. Visão geral da solução
2. Arquitetura final da solução
3. Camada de contexto de produto
4. Funcionalidades do protótipo
5. Matriz de status: implementado, parcial e conceitual
6. Requisitos atendidos e métricas
7. Vídeo de demonstração

1. Visão geral da solução

A Claro opera hoje o site, o app Minha Claro, três números de WhatsApp, chatbots e o call center com inteligências isoladas. O cliente repete a mesma informação a cada troca de canal, o transbordo para o atendimento humano cresce e os squads refazem integrações equivalentes. Na banca da Sprint 2 a Claro acrescentou um segundo eixo ao problema: além dos canais, a solução precisa lidar com os diferentes produtos da operadora. O mesmo titular tem banda larga fixa, linhas móveis, TV, telefonia fixa e, no corporativo, links dedicados e dispositivos conectados.

O ClaroIntelligence responde aos dois eixos com uma camada de orquestração que fica sobre os canais digitais existentes, sem substituí-los. Nenhum canal precisa ser reescrito: eles passam a conversar com um ponto de entrada único que carrega o contexto do cliente, entende de qual produto a conversa trata e detecta o atrito enquanto ele acontece.

Os três componentes

- **ClaroMemory:** memória semântica da jornada. O cliente nunca começa do zero, em nenhum canal. A recuperação é filtrada por cliente e por produto, e cada trecho usado fica registrado com o seu score de similaridade.
- **Persona Engine:** classifica a literacia digital do cliente a partir de padrões de linguagem e adapta tom, vocabulário e nível de detalhe, sem interromper a conversa e sem que a transição seja perceptível.
- **ClaroSense:** calcula um score de atrito a cada turno a partir de sinais como repetição de intenção, mudança de canal, silêncio prolongado e respostas monossilábicas. Acima do limiar de 0,70 o sistema age antes do abandono, em vez de medir a satisfação depois.

O que a arquitetura precisa garantir

- **Continuidade entre canais:** uma jornada iniciada no site continua no WhatsApp sem repetição de informação.
- **Contexto de produto correto:** errar o produto é pior que não responder, porque executa a ação certa no contrato errado.
- **Resposta rápida:** p95 de 2,0 segundos até o primeiro token, com a gravação da memória fora do caminho crítico.
- **Privacidade por desenho:** remoção de dado pessoal antes de qualquer chamada ao modelo de linguagem, consentimento por finalidade e retenção declarada por tipo de dado.

2. Arquitetura final da solução

A solução está organizada em cinco camadas, com uma faixa de governança que atravessa todas elas. A separação não é apenas conceitual: ela aparece na estrutura de pastas do projeto e no contrato de cada módulo. A Figura 1, na página seguinte, apresenta a visão de containers no nível 2 do modelo C4.


2.1 Leitura das camadas

Camada	Responsabilidade	Componentes no protótipo
1. Canais	Pontos de contato do cliente, com sessão independente por canal	Site claro.com.br, App Minha Claro, WhatsApp Claro e a fila de atendimento humano, simulados com identidade visual distinta
2. Borda	Ponto de entrada único da plataforma	API Gateway com autenticação, validação de contrato, rate limit por canal e injeção do trace_id
3. Núcleo de orquestração	Decide o que fazer com o turno antes de qualquer chamada externa	Session Manager, Unified Customer ID, Product Context Resolver, Intent Router e Response Composer
4. Motores de inteligência	Onde está o diferencial da solução	ClaroMemory, Persona Engine e ClaroSense
5. Dados e sistemas de origem	Persistência e tradução para os sistemas legados	SQLite nativo do Node 24, cache em processo, adaptadores por linha de produto e simuladores de Billing, CRM e OSS

Tabela 1: responsabilidade de cada camada da arquitetura.

Arquitetura final da solução ClaroIntelligence

Visão de containers (C4 nível 2): cinco camadas e faixa de governança transversal



Regras de arquitetura invioláveis

1. A resposta ao cliente é síncrona; a gravação da memória é assíncrona e nunca bloqueia o turno.

3. O núcleo nunca conhece o formato de um sistema de origem; toda tradução acontece no adaptador.
2. Orçamento de latência por chamada: acima de 250 ms a memória é ignorada e a resposta é marcada como degradada.

4. Produto novo entra por configuração no catálogo, nunca por alteração de código no núcleo.

Protótipo: React 19 e Vite 8 no front, Node 24 e Express 4 no back, SQLite nativo como banco, sem Docker e sem chave de LLM. | Alvo em produção: PostgreSQL com pgvector, cache distribuído e provedor de linguagem real.

Figura 1: visão de containers no nível 2 do modelo C4, com as cinco camadas e a faixa de governança transversal.

2.2 Stack tecnológica

A escolha das tecnologias seguiu um critério simples: o protótipo precisa subir em qualquer máquina, sem instalação de banco, sem Docker, sem chave de modelo de linguagem e sem variável de ambiente secreta. Uma demonstração que depende de rede ou de infraestrutura externa é uma demonstração que falha na hora da banca.

Camada	Tecnologia	Motivo da escolha
Frontend	React 19, Vite 8, Tailwind CSS v3, React Router v7, Recharts e Lucide React	Interface reativa com gráficos vivos do painel e transmissão da resposta token a token
Backend	Node.js 24 e Express 4	Mesma linguagem nas duas pontas, com suporte nativo a execução assíncrona por evento, que é o que separa o caminho crítico do caminho de aprendizado
Banco de dados	SQLite local, pelo módulo nativo node:sqlite	Sem instalação e sem serviço externo. Guarda as 20 entidades e os vetores da memória semântica
Modelo de linguagem	Provedor simulado determinístico	A apresentação nunca depende de rede nem de chave de API, e o resultado é reproduzível a cada execução
Identificadores	UUID	Chaves estáveis de sessão, mensagem e assinatura, usadas também no trace_id

Tabela 2: stack tecnológica do protótipo funcional.

O provedor de modelo de linguagem é plugável: a troca por um provedor real acontece por configuração, sem alteração no núcleo. Da mesma forma, a persistência está isolada atrás de um repositório, de modo que a migração do SQLite para PostgreSQL com pgvector, prevista para produção, não toca as regras de negócio. O que o protótipo não faz é esconder essa diferença: a Figura 1 e a matriz do capítulo 5 declaram o que roda hoje e qual é o alvo.

2.3 Regras de arquitetura que não podem ser violadas

- Caminho crítico separado do caminho de aprendizado. A resposta ao cliente é síncrona; a gravação da memória é assíncrona, disparada por evento ao fim do turno, e nunca bloqueia a resposta.
- Orçamento de latência declarado por chamada. A recuperação de memória tem limite de 250 ms. Acima disso o sistema responde sem contexto, marca a resposta como degradada e registra o evento, que fica visível na interface e não apenas no log.
- Camada anticorrupção diante dos sistemas de origem. O núcleo nunca conhece o formato de um sistema de suporte ao negócio; cada linha de produto tem um adaptador que traduz para um contrato interno único.
- Provedor de modelo de linguagem plugável. A troca de provedor acontece por configuração, sem alteração no núcleo, e existe um provedor simulado determinístico para que a apresentação nunca dependa de rede.

2.4 O caminho de uma mensagem, do canal à resposta

A sequência abaixo descreve o que acontece a cada turno de conversa e é a mesma para os três canais simulados.

1. O canal envia a mensagem ao API Gateway, que valida o contrato, aplica o rate limit e injeta o trace_id que acompanha toda a cadeia.
2. O Session Manager recupera ou cria a sessão, com o canal de origem e a assinatura em foco, se já houver uma.

3. O Unified Customer ID consolida as identidades externas e devolve um cliente único, independentemente do canal de entrada.
4. O Product Context Resolver define de qual produto a conversa trata, nas cinco etapas descritas no capítulo 3.
5. O ClaroMemory recupera o contexto semântico, filtrado por cliente e por produto, com orçamento de 250 ms.
6. O Intent Router classifica a intenção e registra a confiança. A intenção e o produto formam um par, não dois campos soltos.
7. O adaptador da linha de produto consulta o sistema de origem e devolve os dados no contrato interno único.
8. A Persona Engine define o tom e o nível de detalhe, e o Response Composer transmite a resposta token a token.
9. O ClaroSense pontua o atrito do turno e, acima de 0,70, dispara a intervenção proativa ou o transbordo com histórico preservado.
10. Ao fim do turno, um evento assíncrono grava o resumo pseudonimizado na memória vetorial, já com o código do produto nos metadados.

3. Camada de contexto de produto

Esta é a parte mais diferenciada do projeto e responde diretamente ao questionamento levantado pela Claro na banca. A frase “minha internet caiu” pode se referir à fibra da casa, ao FWA 5G, à franquia do celular ou à conexão do Box de TV. Como a base convergente da Claro, com serviço móvel e residencial no mesmo cliente, já cresce a dois dígitos ao ano, a ambiguidade de produto é a regra e não o caso de borda.

A dificuldade é estrutural: cada linha de produto tem uma chave de identificação diferente, herdada de plataformas distintas. O móvel se identifica pela linha, o residencial pelo ponto de instalação, a TV pela assinatura e o corporativo pelo CNPJ com contratos por site. Consolidar marcas não consolidou os sistemas por trás delas.

3.1 Chaves de identificação por linha de produto

Linha de produto	Chave real de identificação	Consequência para a solução
Móvel	A linha, ou seja, o MSISDN, sob uma conta de faturamento	Um titular com duas linhas tem dois contextos possíveis para a mesma pergunta
Banda larga e telefonia fixa	O ponto de instalação, ou seja, o endereço	O mesmo CPF com duas casas tem dois contratos distintos
TV e streaming	Assinatura vinculada ao CPF ou ao ponto	Add-ons de streaming e pontos adicionais pertencem à assinatura, não ao cliente
Corporativo	CNPJ, com múltiplos contratos por site e centro de custo	A desambiguação passa a considerar também o site e o rateio

Tabela 3: por que a resolução de produto precisa ser uma etapa própria do núcleo.


3.2 Códigos de erro próprios da camada

Código	Quando é retornado
product_ambiguous	Há mais de um produto elegível e a inferência não atingiu a confiança mínima. O sistema faz uma única pergunta de desambiguação, em uma frase.
product_not_contracted	O produto identificado não consta no portfólio do titular. A resposta orienta a contratação em vez de simular um atendimento inexistente.
capability_unsupported	A intenção detectada não é suportada por aquela linha de produto, segundo a matriz de capacidades.

Tabela 4: erros de negócio criados para a camada de produto.

Camada de contexto de produto: Product Context Resolver

Como a solução decide, antes de agir, sobre qual produto do titular a conversa está falando



A intenção e o produto são um par: intencao carrega codigo_produto e confianca_produto, e a sessão guarda id_assinatura_foco para não perguntar o produto a cada turno.

Figura 2: as cinco etapas do Product Context Resolver, os adaptadores por linha de produto e o catálogo como fonte única de verdade.

4. Funcionalidades do protótipo

O protótipo é uma aplicação web funcional, com back-end e front-end, dividida em duas frentes: a interface do cliente, onde a conversa acontece, e o painel administrativo, onde a operação enxerga o que a inteligência está fazendo. As capturas a seguir são das telas em execução.

4.1 Dashboard de Jornada

Tela de abertura do painel. Reúne os indicadores vivos gerados pelo próprio protótipo: total de atendimentos, First Call Resolution, CES médio e número de intervenções do ClaroSense, cada um com a variação em relação ao período anterior. O gráfico de volume por canal mostra a migração do call center para os canais digitais ao longo das semanas, e a taxa de transbordo semana a semana registra a redução progressiva de 28% para 8%. A leitura da tela responde à primeira pergunta da operação: o volume está indo para onde deveria ir.




Figura 3: Dashboard de Jornada com indicadores, volume por canal e taxa de transbordo.

4.2 Mapa de Atrito

Localiza onde o cliente sofre. O índice de atrito é calculado por jornada, em escala de 0 a 100, com faixas de cor, e a jornada crítica aparece em destaque. Ao lado, os sinais de atrito detectados no período são quantificados um a um: repetição de intenção, mudança de canal, silêncio prolongado e respostas monossilábicas. O mapa de calor cruza canal e jornada e mostra, por exemplo, que o cancelamento pelo call center concentra o maior atrito da operação. Cada célula acima do limiar vira um alerta com ação sugerida.




Figura 4: Mapa de Atrito por jornada, sinais detectados e mapa de calor entre canal e jornada.

4.3 Monitor de Conversas

É a tela do supervisor. Lista as conversas em andamento com o nível de atrito de cada uma, o canal, a jornada e o tempo desde a última interação, com filtros por situação: em risco, transferidas e resolvidas. Cada cartão traz o motivo em uma frase, escrito a partir do sinal que o ClaroSense detectou. O atendente humano assume a conversa com todo o histórico e o contexto preservados, sem que o cliente precise repetir nada, que é exatamente o ponto de falha do processo atual.




Figura 5: Monitor de Conversas com fila de sessões em risco e assunção por atendente humano.

4.4 Chat do Cliente e painel de transparência

A interface do cliente simula os três canais, com aparência distinta e sessão independente, o que permite demonstrar a continuidade entre canais em uma única tela. A resposta é transmitida token a token. À direita, o painel de transparência mostra em tempo real a intenção detectada com o seu grau de confiança, o produto resolvido pela camada de contexto, a persona identificada, o score de atrito do turno e quais trechos de memória foram recuperados. Esse painel é o que transforma a arquitetura em algo visível: a banca não precisa acreditar na descrição, ela vê a decisão sendo tomada.




Figura 6: Chat do Cliente com o painel de transparência da inteligência artificial à direita.

4.5 Log do ClaroSense

Registra cada intervenção do motor de atrito: horário, canal, sinal detectado, ação tomada e resultado. O acumulado por tipo de intervenção separa acionamento de atendimento humano, simplificação de fluxo, mudança de canal e antecipação. Os indicadores do topo consolidam o efeito: intervenções no dia, redução do acionamento humano e churn evitado estimado. É a trilha que permite auditar a decisão do sistema depois, e não apenas observá-la enquanto acontece.




Figura 7: Log do ClaroSense com intervenções por tipo e trilha em tempo real.

4.6 Gestão de Personas

Configura a Persona Engine sem nova liberação de código. Os três perfis, usuário digital, intermediário e assistido, aparecem com as suas características e com um exemplo real de adaptação: a mesma pergunta recebe respostas com vocabulário e profundidade diferentes. Abaixo ficam os controles do motor, como o limiar de detecção de literacia, a sensibilidade de adaptação e o atraso para reclassificação, além de um campo para testar a adaptação ao vivo e ver qual perfil seria identificado.




Figura 8: Gestão de Personas com exemplos de adaptação e parâmetros configuráveis do motor.

5. Matriz de status: implementado, parcial e conceitual

A banca pediu explicitamente uma leitura honesta do que está pronto. A matriz abaixo separa o que roda no protótipo, o que existe de forma parcial e o que permanece conceitual e dependeria de acesso aos sistemas reais da Claro.

Item	Status	Observação
Núcleo de orquestração e API de mensagens	Implementado	Ponto de entrada único, sessão, trace_id e contrato versionado
Unified Customer ID	Implementado	Consolidação de identidades externas em um cliente único
ClaroMemory: escrita e leitura	Implementado	Gravação assíncrona e recuperação com orçamento de 250 ms
Continuidade entre canais	Implementado	Demonstrada no roteiro do site para o WhatsApp
Product Context Resolver e adaptadores	Implementado	Adaptadores móvel, residencial e tv contra simuladores; empresas e iot declarados
Dashboard de Jornada e Mapa de Atrito	Implementado	Indicadores gerados pelo próprio protótipo, sem dado fixo no front
Persona Engine	Parcial	Três perfis fixos e reclassificação por sinais; ainda sem aprendizado contínuo
ClaroSense	Parcial	Quatro sinais de atrito com score por turno; catálogo de intervenções ainda reduzido
Monitor de Conversas e transbordo	Parcial	Assunção por humano funciona; roteamento por especialidade fica em aberto
Persistência em PostgreSQL com pgvector	Conceitual	O protótipo usa SQLite nativo do Node 24, sem serviço externo; a troca fica isolada no repositório

Item	Status	Observação
Integrações reais com Billing, CRM e OSS	Conceitual	O protótipo usa simuladores com latência artificial e falhas ocasionais
Canais em produção e fila de eventos	Conceitual	Depende de infraestrutura da operadora
Trilha de auditoria imutável e cofre de chaves	Conceitual	Desenhados no documento de arquitetura, fora do escopo do protótipo

Tabela 5: estado real de cada item da solução no encerramento da Sprint 4.

6. Requisitos atendidos e métricas

Os requisitos funcionais priorizados no protótipo são demonstráveis na interface e cobertos por teste automatizado. Os requisitos não funcionais têm métrica objetiva e forma de prova.

6.1 Requisitos funcionais demonstráveis

ID	Requisito	Onde é demonstrado
RF01	Identificar o cliente de forma única a partir de qualquer canal	Chat do Cliente, painel de transparência
RF02	Recuperar contexto semântico antes de gerar a resposta	Painel de transparência, bloco ClaroMemory
RF03	Continuar em outro canal uma jornada iniciada, sem repetição	Roteiro de continuidade entre canais
RF04	Classificar a intenção com nível de confiança registrado	Painel de transparência, intenção detectada
RF21	Recuperar o portfólio contratado do titular	Product Context Resolver, etapa 2
RF22	Desambiguar o produto quando houver mais de um elegível	Roteiro de desambiguação multiproduto
RF23	Verificar a capacidade do produto antes de agir	Matriz de capacidades, erro capability_unsupported
RF06	Detectar sinais de atrito e calcular score por turno	Log do ClaroSense e Monitor de Conversas
RF07	Acionar intervenção proativa acima do limiar	Log do ClaroSense, coluna de ação tomada
RF08	Transferir para humano preservando histórico e contexto	Monitor de Conversas, assunção da sessão
RF05	Adaptar tom e nível de detalhe ao perfil do cliente	Gestão de Personas e teste de adaptação ao vivo
RF18	Dashboard de jornada com volume, FCR, CES e transbordo	Dashboard de Jornada
RF19	Mapa de atrito por jornada e etapa, com alerta de limiar	Mapa de Atrito
RF20	Configurar personas, limiares e regras pelo painel	Gestão de Personas e Configurações

Tabela 6: requisitos funcionais priorizados e o ponto do protótipo onde cada um aparece.

6.2 Requisitos não funcionais e metas

ID	Requisito	Meta declarada
RNF01	Tempo até o primeiro token	p95 de 2,0 s e p99 de 3,5 s
RNF03	Taxa de erro	Menos de 0,5% de erros 5xx e menos de 2% de resposta degradada
RNF06	Latência da memória	Recuperação p95 de 250 ms e gravação em até 1 s
RNF07	Segurança	TLS, segredos fora do código e nenhum dado pessoal em log
RNF09	Observabilidade	100% das interações com trace_id ponta a ponta
RNF12	Portabilidade de modelo	Troca de provedor de linguagem por configuração
RNF13	Manutenibilidade	Cobertura mínima de 80% no núcleo e contrato OpenAPI versionado

Tabela 7: requisitos não funcionais com métrica objetiva.

7. Vídeo de demonstração

O vídeo apresenta a equipe e percorre o protótipo em funcionamento, com os roteiros de continuidade entre canais, desambiguação multiproduto, detecção de atrito com transbordo para o atendimento humano e navegação pelo painel administrativo.

Link de acesso ao vídeo: <https://youtu.be/NAFeMhycqoE>