

Faculdade de Informática e Administração Paulista
Sistemas de Informação

Guilherme Korus Daoud RM 97826
Marcos Henrique Ribeiro de Santana RM 98561
Rafael Jun Miura RM 98845
Raphael Oliveira Batizati RM 99949
Sérgio Nogueira RM 98577

ClaroIntelligence

Challenge Sprint 4

Documento de melhorias: antes e depois

Evolução técnica da solução a partir dos feedbacks da banca e das mentorias

São Paulo/SP
2026

Sumário

1. Introdução e escopo desta entrega	3
1.1 As seis melhorias desta sprint	3
2. Quadro de rastreabilidade dos feedbacks	4
3. Melhoria 1: arquitetura técnica detalhada e diagrama legível	7
3.1 Antes	7
3.2 Depois	7
3.3 Justificativa	10
4. Melhoria 2: contrato de APIs e modelo de dados	13
4.1 Antes	13
4.2 Depois: contrato de APIs	13
4.3 Depois: modelo de dados	17
4.4 Depois: como a memória semântica é gravada e recuperada	19
4.5 Justificativa	21
5. Melhoria 3: segurança, privacidade e conformidade com a LGPD	22
5.1 Antes	22
5.2 Depois	22
5.3 Justificativa	25
6. Melhoria 4: requisitos formais e métricas objetivas	26
6.1 Antes	26
6.2 Depois: requisitos funcionais	26
6.3 Depois: requisitos não funcionais e métricas de desempenho	29
6.4 Justificativa	31
7. Melhoria 5: experiência conversacional, fluxogramas e protótipo visual	32
7.1 Antes e a ampliação dos cenários	32
7.2 Antes e depois dos fluxogramas	32
7.3 Antes e depois da interface administrativa	35
7.4 Justificativa	37
8. Melhoria 6: integração dos diferentes produtos da Claro	38
8.1 Antes e o questionamento da Claro	38
8.2 Depois: o portfólio mapeado	38
8.3 Depois: a camada de contexto de produto	41
8.4 Depois: extensão do modelo de dados	43
8.5 Depois: reflexo nas APIs, nos requisitos e nos cenários	45
8.6 Justificativa	45
9. Estado atual do protótipo: implementado, parcial e conceitual	46
10. Vídeo de demonstração	49
11. Considerações finais	49
Anexo A. Catálogo de endpoints e payloads	51
Anexo B. Dicionário de dados	54
Anexo C. Backlog de cenários conversacionais	56

1. Introdução e escopo desta entrega

O ClaroIntelligence é uma camada de orquestração com inteligência artificial que atua sobre os canais digitais já existentes da Claro, sem substituí-los. A proposta nasceu do diagnóstico apresentado na Sprint 1: a Claro opera site, aplicativo Minha Claro, três números de WhatsApp, chatbots e call center com inteligências isoladas, de modo que o cliente repete informações a cada troca de canal, o transbordo para o atendimento humano cresce e os squads refazem integrações equivalentes. A resposta proposta se apoia em três componentes: o ClaroMemory, que dá memória semântica à jornada; a Persona Engine, que adapta a comunicação ao perfil do cliente; e o ClaroSense, que detecta atrito durante a conversa e age antes do abandono.

A Sprint 2 aprofundou a arquitetura e a experiência conversacional. A avaliação daquela entrega, feita pelos professores e pela equipe da Claro, apontou um conjunto consistente de lacunas: a arquitetura permanecia mais conceitual do que técnica, faltavam contratos de API e modelo de dados, segurança e LGPD estavam pouco detalhadas, os requisitos não haviam sido formalizados, não havia métricas objetivas de desempenho, a memória semântica era citada mas não explicada, a interface administrativa não tinha representação visual e não estava claro o que já existia no protótipo e o que ainda era intenção. A própria Claro acrescentou, na banca, um questionamento de escopo: como a solução integraria não apenas os canais de comunicação, mas os diferentes produtos da operadora.

Esta entrega da Sprint 4 responde a esses pontos. O documento está organizado em seis melhorias, cada uma com a mesma estrutura: o que existia antes, o que passou a existir depois e a justificativa da mudança. As figuras comparativas usam a marcação ANTES e DEPOIS e as figuras técnicas mais densas ocupam páginas inteiras em orientação paisagem, de forma que possam ser lidas sem ampliação. O capítulo 9 apresenta a matriz que separa, item a item, o que já funciona no protótipo do que permanece como proposta conceitual. O capítulo 10 traz o vídeo de demonstração.

Link do vídeo de demonstração

Duração entre 3 e 5 minutos, com toda a equipe em câmera aberta, comparando a versão anterior e a versão atual do sistema funcional. Acesso público em: [INSERIR AQUI O LINK PÚBLICO DO VÍDEO]

1.1 As seis melhorias desta sprint

- Melhoria 1: arquitetura técnica detalhada, com protocolos, integrações, fluxo de dados e diagrama legível em página inteira.
- Melhoria 2: contrato de APIs com endpoints, payloads e respostas, modelo de dados com quatorze entidades e explicação do funcionamento da memória semântica.
- Melhoria 3: segurança, privacidade e conformidade com a LGPD, cobrindo consentimento, retenção, exclusão, criptografia, pseudonimização e controle de acesso.
- Melhoria 4: requisitos funcionais e não funcionais formalizados, com métricas objetivas de desempenho, disponibilidade, taxa de erro e volume de usuários simultâneos.
- Melhoria 5: experiência conversacional ampliada, com catálogo de cenários transformados em backlog, fluxogramas em notação de raias e wireframes do painel administrativo.
- Melhoria 6: integração dos diferentes produtos da Claro, com o portfólio mapeado, uma camada de contexto de produto, adaptadores por linha de produto e a extensão do modelo de dados.

2. Quadro de rastreabilidade dos feedbacks

A tabela a seguir liga cada feedback recebido à melhoria correspondente e ao ponto exato deste documento em que ele foi endereçado. Nenhum item recebido foi deixado de fora: os treze pontos levantados, incluindo as duas sugestões abertas e o questionamento de escopo trazido pela Claro na banca, estão cobertos pelas seis melhorias.

Tabela 1: rastreabilidade entre os feedbacks recebidos e as melhorias implementadas.

#	Feedback recebido na banca e nas mentorias	Melhoria implementada	Onde verificar
1	A arquitetura ainda está mais conceitual do que técnica; faltou detalhar protocolos, integrações, APIs e fluxo de dados.	Melhoria 1	Cap. 3, Figuras 1B e 2, Tabela 2
2	O diagrama da arquitetura ficou pequeno e com baixa legibilidade.	Melhoria 1	Cap. 3, Figura 1B em página de paisagem
3	Faltaram exemplos de endpoints, payloads JSON e respostas esperadas.	Melhoria 2	Cap. 4.2, Tabela 3 e Anexo A
4	Faltou modelo de dados com as entidades cliente, sessão, canal, mensagem, intenção, vetor, contexto, atrito, intervenção e histórico.	Melhoria 2	Cap. 4.3, Figura 3 e Anexo B
5	O uso de LLM, Vector DB, Pinecone/Weaviate e embeddings foi citado, mas faltou explicar como a memória semântica é gravada e recuperada.	Melhoria 2	Cap. 4.4 e Figura 4
6	Segurança e LGPD foram pouco detalhadas; faltou consentimento, retenção, exclusão, criptografia, pseudonimização e controle de acesso.	Melhoria 3	Cap. 5 e Figura 5
7	Os requisitos funcionais e não funcionais não foram estruturados formalmente na Sprint 2.	Melhoria 4	Cap. 6.1, Tabela 5
8	Faltaram métricas objetivas de desempenho, como tempo de resposta, disponibilidade, taxa de erro e volume de usuários simultâneos.	Melhoria 4	Cap. 6.2, Tabela 6
9	A interface administrativa foi bem descrita, mas faltaram telas, wireframes ou protótipo visual.	Melhoria 5	Cap. 7.3 e Figura 7B
10	Faltou deixar claro o que já está implementado no protótipo e o que ainda é proposta conceitual.	Melhoria 5	Cap. 8, Tabela 7
11	Sugestão: existem outros cenários a mapear (consultar fatura, segunda via, consultar plano, alterar plano, reportar problema técnico, reagendar visita, solicitar atendente humano). Eles poderiam virar tarefas de desenvolvimento e base de teste.	Melhoria 5	Cap. 7.1 e Anexo C
12	Sugestão: há outra forma de apresentar os fluxogramas? A forma apresentada dificulta a leitura.	Melhoria 5	Cap. 7.2, Figura 6B
13	Questionamento da Claro na banca: além dos canais de comunicação, como a solução vai integrar os diferentes produtos da operadora, e não apenas internet? Banda larga, móvel, TV, telefonia fixa, residencial e corporativo.	Melhoria 6	Cap. 8, Figuras 8, 9 e 10, Tabela 7

3. Melhoria 1: arquitetura técnica detalhada e diagrama legível

3.1 Antes

Na Sprint 2, a arquitetura foi apresentada como uma sequência vertical de blocos: canais, API Gateway, Unified Customer ID e, abaixo, os três motores. O texto descrevia o papel de cada bloco em linguagem de negócio, mas o desenho não informava por qual protocolo os blocos conversavam, que formato de mensagem trafegava entre eles, onde os dados eram persistidos, qual era o comportamento em caso de falha nem quais sistemas da Claro seriam consumidos. A tabela de componentes técnicos citava tecnologias, porém sem contratos: dizer que existe um API Gateway REST ou GraphQL não permite que outro time implemente contra aquela interface.

Havia ainda um problema de forma. O diagrama foi inserido em tamanho reduzido dentro de uma página em retrato, com rótulos abaixo do limite confortável de leitura, o que a banca registrou como baixa legibilidade.

Figura 1A | ANTES (Sprint 2)

Reconstrução do diagrama entregue: blocos conceituais, sem protocolos, sem contratos e sem camada de dados.




Figura 1A: reconstrução do diagrama de arquitetura entregue na Sprint 2.

3.2 Depois

A arquitetura foi reescrita como um diagrama de containers no estilo C4 nível 2, organizado em cinco camadas horizontais e uma faixa de governança transversal. Cada elemento passou a declarar a tecnologia que o implementa e cada conexão passou a declarar protocolo, formato de mensagem, mecanismo de autenticação e tempo limite. O diagrama ocupa uma página inteira em orientação paisagem e traz, no rodapé, a legenda de status que distingue o que já funciona no protótipo do que é proposta.

Três decisões arquiteturais merecem destaque, porque respondem diretamente à observação de que a proposta era conceitual demais. A primeira é a separação entre o caminho crítico da resposta, que precisa ser síncrono e rápido, e o caminho de aprendizado, que é assíncrono e passa pelo barramento de eventos. A segunda é a camada anticorrupção diante dos sistemas legados da Claro, que isola o núcleo do contrato SOAP do faturamento e permite evoluir os dois lados de forma independente. A terceira é o orçamento de latência declarado por chamada, que transforma a arquitetura em algo verificável: se a recuperação de memória ultrapassa duzentos e cinquenta milissegundos, o sistema responde sem contexto e registra a degradação, em vez de deixar o cliente esperando.

Figura 1B | DEPOIS (Sprint 4) - Diagrama de containers C4 (nível 2) do ClaroIntelligence

Protocolos, contratos de integração, armazenamento e fluxo de dados explícitos. Legenda de status no rodapé.




Figura 1B: diagrama de containers C4 nível 2 do ClaroIntelligence, com protocolos, contratos e status de implementação.

Tabela 2: protocolos, formatos, autenticação e tempos limite de cada integração.

Integração	Protocolo e transporte	Formato	Autenticação	Tempo limite
Canal (app, site) para API Gateway	HTTPS 1.1 (REST) e WebSocket para o streaming da resposta	JSON	OAuth 2.0 client credentials, JWT de curta duração (15 min)	3 s
WhatsApp Cloud API para Webhook	HTTPS POST de entrada	JSON	Assinatura HMAC-SHA256 no cabeçalho X-Hub-Signature-256	5 s
API Gateway para Núcleo de Orquestração	gRPC sobre HTTP/2	Protobuf	mTLS entre serviços, com certificados rotacionados	800 ms, 2 tentativas
Núcleo para ClaroMemory	gRPC	Protobuf	mTLS	250 ms
ClaroMemory para Vector Database	HTTPS (SDK oficial Pinecone ou Weaviate)	JSON	Chave de API guardada no cofre KMS	150 ms
Núcleo para provedor de LLM	HTTPS com resposta em Server-Sent Events	JSON	Chave de API, contrato com retenção zero de dados	20 s
Núcleo para Event Bus	Protocolo binário Kafka sobre TCP	Avro, com Schema Registry	SASL/SCRAM sobre TLS	assíncrono
Adaptador para BSS Móvel (pré, controle, pós, flex)	REST através de camada anticorrupção	JSON	mTLS e token de serviço	2 s
Adaptador para BSS Residencial (fibra e HFC legado)	REST na borda, encapsulando o SOAP legado	JSON na borda, XML no legado	mTLS e token de serviço	2 s
Adaptador para Plataforma Claro tv+	REST	JSON	OAuth 2.0	2 s
Adaptador para BSS Claro Empresas (ex-Embratel)	REST, com fila para operações de provisionamento	JSON	mTLS	3 s
Adaptador para Plataforma IoT e M2M	REST	JSON	mTLS	3 s
Núcleo para CRM da Claro	REST	JSON	OAuth 2.0	2 s
Núcleo para OSS e diagnóstico de rede	REST	JSON	mTLS	4 s
Painel Administrativo para APIs internas	HTTPS (REST)	JSON	OIDC com RBAC por papel	1 s

Fluxo de dados de uma interação

A Figura 2 detalha a sequência completa de uma interação, do momento em que o cliente envia a mensagem até a gravação do turno como memória. Os passos de um a onze compõem o caminho crítico e determinam o tempo de resposta percebido. Os passos doze a quinze acontecem depois que o cliente já recebeu a resposta e, por isso, não entram no orçamento de latência.

3.3 Justificativa

A observação da banca foi precisa: uma arquitetura sem protocolo, contrato e comportamento de falha não é uma arquitetura, é um organograma de componentes. Um desenho nesse nível não permite que um time de engenharia estime esforço, não permite que a área de segurança avalie superfície de exposição e não permite que a Claro julgue viabilidade técnica, que foi justamente um dos pedidos explícitos do kick-off.

O detalhamento também tem efeito prático sobre o próprio projeto. Ao declarar protocolos e tempos limite, o time passou a ter critérios de aceite verificáveis para o protótipo, e não apenas uma descrição narrativa. E ao separar o caminho crítico do caminho assíncrono, ficou evidente onde investir em desempenho e onde é aceitável perder tempo em troca de qualidade de memória. A mudança de forma, com a figura em página de paisagem, resolve o segundo ponto: uma arquitetura que não pode ser lida não pode ser avaliada.

Figura 2 | Fluxo de dados de uma interação ponta a ponta (diagrama de sequencia)

Cada seta indica o protocolo e o contrato usado. Passos 12 a 15 ocorrem fora do caminho crítico da resposta.




Figura 2: fluxo de dados de uma interação ponta a ponta, com protocolo e contrato em cada passo.

4. Melhoria 2: contrato de APIs e modelo de dados

4.1 Antes

A Sprint 2 mencionava um API Gateway e um SDK compartilhado em Python e Node.js, mas não apresentava um único endpoint, nenhum exemplo de corpo de requisição, nenhuma resposta esperada e nenhum tratamento de erro. Do lado dos dados, o documento falava em memória semântica, embeddings e Vector Database sem definir quais entidades existiam, que atributos elas carregavam, como se relacionavam e por quanto tempo seriam guardadas. Na prática, um squad da Claro que quisesse integrar um canal novo não teria contra o que programar.

4.2 Depois: contrato de APIs

A solução passou a expor um contrato REST versionado, descrito em OpenAPI 3.1 e publicado junto ao repositório do protótipo. Todas as rotas usam o prefixo de versão, aceitam e devolvem JSON em UTF-8, exigem o cabeçalho Idempotency-Key nas operações de escrita e propagam um identificador de rastreamento por interação. A Tabela 3 resume o catálogo; o Anexo A traz os corpos completos das rotas principais.

Tabela 3: catálogo de endpoints da API do ClaroIntelligence.

Método e caminho	Função	Consumidor	Status
POST /v1/sessions	Abre uma sessão em um canal e devolve o identificador de continuidade.	Canais	Implementado
POST /v1/conversations/{id_sessao}/messages	Envia uma mensagem do cliente e recebe a resposta gerada, com streaming opcional.	Canais	Implementado
GET /v1/customers/resolve	Resolve o Unified Customer ID a partir de CPF, MSISDN, id do app ou contrato.	Canais e núcleo	Implementado
GET /v1/customers/{id_cliente}/context	Devolve o bloco de contexto semântico usado na próxima resposta.	Núcleo e painel	Implementado
POST /v1/memory/records	Grava um turno como memória semântica (chamada assíncrona).	Núcleo	Implementado
POST /v1/friction/score	Calcula o score de atrito de um turno a partir dos sinais observados.	ClaroSense	Parcial
POST /v1/interventions	Registra e executa uma intervenção proativa.	ClaroSense	Parcial
GET /v1/personas/{id_cliente}	Devolve a diretiva de tom e complexidade do cliente.	Núcleo	Parcial
PUT /v1/admin/personas/{id_perfil}	Ajusta manualmente um perfil de comunicação.	Painel	Parcial
GET /v1/admin/journeys/friction-map	Devolve a matriz de atrito por jornada e etapa.	Painel	Implementado
GET /v1/admin/sessions	Lista sessões com filtro por canal, intenção, score e período.	Painel	Implementado
POST /v1/privacy/consents	Registra ou revoga consentimento por finalidade.	Canais e painel	Conceitual
POST /v1/privacy/erasure-requests	Abre pedido de exclusão ou portabilidade de dados do titular.	Canais e painel	Conceitual
GET /v1/customers/{id_cliente}/products	Devolve o portfólio contratado do titular: contas, contratos e assinaturas ativas.	Núcleo e painel	Parcial
POST /v1/conversations/{id_sessao}/product-focus	Fixa a assinatura de produto em foco na sessão após a desambiguação.	Núcleo	Parcial
GET /v1/catalog/products	Lista o catálogo de produtos, com linha, família e adaptador.	Núcleo e painel	Parcial
GET /v1/catalog/products/{codigo}/capabilities	Devolve a matriz de intenções suportadas por aquele produto.	Núcleo	Parcial
GET /v1/health e /v1/ready	Sondas de saúde e prontidão usadas pelo orquestrador de contêineres.	Infraestrutura	Implementado

Exemplo 1: envio de mensagem do cliente

Esta é a rota mais usada da solução. O canal envia o texto do cliente e recebe a resposta já composta, com o contexto recuperado, a intenção classificada e o score de atrito do turno. O campo stream, quando verdadeiro, faz a resposta ser entregue por Server-Sent Events, token a token.

```
POST /v1/conversations/ses_74be21c9/messages HTTP/1.1
Host: api.clarointelligence.claro.com.br
Authorization: Bearer eyJhbGciOiJSUzI1NiIsInR5cCI6IkpXVCJ9...
Idempotency-Key: 9f2c1b44-77aa-4f1e-9c30-2b8d6a51e004
Content-Type: application/json

{
  "canal": "site",
  "id_externo": "web_sess_8831",
  "texto": "minha internet continua ruim",
  "stream": true,
  "metadados": {
    "user_agent": "Mozilla/5.0",
    "origem_pagina": "/suporte/internet"
  }
}
```

Resposta 200 OK, no formato consolidado (sem streaming):

```
{
  "id_mensagem": "msg_5c81d0",
  "id_sessao": "ses_74be21c9",
  "id_cliente": "cli_8ad3f1c7",
  "resposta": "Oi, Guilherme. Vi que você começou um atendimento pelo site",
    há pouco, sobre instabilidade na internet residencial.
    O diagnóstico remoto já foi iniciado. Quer continuar daqui?",
  "intencao": {
    "codigo": "suporte_tecnico_conexao",
    "confianca": 0.94,
    "entidades": { "servico": "banda_larga", "escopo": "residencial" }
  },
  "contexto_utilizado": [
    { "id_vetor": "vec_9f2c", "score": 0.881, "canal_origem": "site",
      "data": "2026-08-14T19:22:10Z" },
    { "id_vetor": "vec_31a7", "score": 0.804, "canal_origem": "app",
      "data": "2026-08-02T11:05:44Z" }
  ],
  "atrito": { "score": 0.42, "sinais": ["repeticao_intencao"] },
  "persona_aplicada": { "tom": "objetivo", "nivel_detalhe": 2 },
  "latencia_ms": { "memoria": 88, "llm": 1310, "total": 1512 },
  "trace_id": "4f9c2ad1b77e4a10"
}
```

Exemplo 2: recuperação de contexto

Rota usada pelo núcleo antes de compor o prompt e pelo painel administrativo quando um atendente humano assume a conversa. Ela devolve exatamente o bloco de contexto que será entregue ao modelo, o que torna auditável a decisão tomada.

```
GET /v1/customers/cli_8ad3f1c7/context?top_k=8&janela_dias=90&canal=site

200 OK
{
  "id_cliente": "cli_8ad3f1c7",
  "gerado_em": "2026-08-19T14:02:11Z",
  "tokens_totais": 1140,
  "trechos": [
    {
      "id_vetor": "vec_9f2c",
      "score_similaridade": 0.881,
      "resumo": "Cliente relatou queda de internet residencial; diagnóstico remoto iniciado, não concluído.",
      "canal": "site",
      "intencao": "suporte_tecnico_conexao",
      "resolvida": false,
      "criado_em": "2026-08-14T19:22:10Z"
    }
  ],
  "degradado": false
}
```

Exemplo 3: score de atrito e intervenção

O ClaroSense recebe os sinais observados no turno e devolve o score consolidado, o limiar vigente e a ação recomendada. A separação entre cálculo e execução permite operar o componente em modo sombra, apenas observando, antes de deixá-lo agir sobre a conversa.

```
POST /v1/friction/score
{
  "id_sessao": "ses_74be21c9",
  "id_mensagem": "msg_5c81d0",
  "sinais": [
    { "tipo": "repeticao_intencao", "peso": 0.34 },
    { "tipo": "sentimento", "valor": -0.51, "peso": 0.28 },
    { "tipo": "latencia_resposta_cliente", "segundos": 96, "peso": 0.16 }
  ]
}

200 OK
{
  "score": 0.78,
  "limiar": 0.70,
  "acima_do_limiar": true,
  "acao_recomendada": "transferir_humano",
  "justificativa": "Intenção repetida duas vezes sem resolução e sentimento negativo crescente.",
  "id_intervencao_sugerida": "itv_a91b34"
}
```

Padrão de erro

Todas as rotas devolvem erro no mesmo formato, com código interno estável, mensagem legível e o identificador de rastreamento, de modo que o canal saiba distinguir entre repetir a chamada, renovar a credencial ou seguir por um caminho alternativo.

```
503 Service Unavailable
{
  "erro": {
    "codigo": "memory_degraded",
    "mensagem": "Memória semântica indisponível; resposta gerada sem contexto.",
    "recuperavel": true,
    "trace_id": "4f9c2ad1b77e4a10"
  }
}
```


4.3 Depois: modelo de dados

O modelo lógico foi definido com quatorze entidades, cobrindo todas as que a banca citou e mais quatro necessárias para dar conta de identidade externa, consentimento, personalização e auditoria. A Figura 3 apresenta o diagrama entidade-relacionamento; o Anexo B traz o dicionário com finalidade, prazo de retenção e tratamento de dado pessoal de cada entidade.

Duas escolhas estruturam o modelo. A primeira é a separação entre o texto integral da conversa, que fica cifrado no banco relacional e tem retenção de doze meses, e o resumo pseudonimizado, que é vetorizado e tem retenção de vinte e quatro meses. Isso permite manter memória longa sem manter dado pessoal em excesso. A segunda é a entidade `contexto_recuperado`, que registra quais trechos foram efetivamente usados em cada resposta e com que score. Sem esse registro, não haveria como explicar por que o sistema respondeu de determinada maneira, o que é um problema de auditoria e também de melhoria contínua.

Figura 3 | Modelo de dados lógico do ClaroIntelligence (DER)

14 entidades. PK em negrito, FK marcada com (FK). Tipos e regras de retenção detalhados no Anexo B.



Cores: vermelho = identidade do cliente e atrito | verde-agua = jornada conversacional | azul = memória semântica | roxo = privacidade e auditoria | âmbar = personalização | verde = indicadores

Figura 3: modelo de dados lógico com quatorze entidades, chaves e cardinalidades.

4.4 Depois: como a memória semântica é gravada e recuperada

Este era o ponto em que a Sprint 2 apenas citava tecnologias. A memória semântica passou a ser descrita como dois caminhos independentes, com etapas, parâmetros e orçamento de tempo próprios.

No caminho de escrita, disparado por evento ao final de cada turno, o texto passa primeiro por uma etapa de remoção de dados pessoais, feita com expressões regulares e reconhecimento de entidades nomeadas, que retira CPF, número de cartão, endereço e telefone. Em seguida o conteúdo é quebrado em janelas de quatrocentos tokens com sobreposição de sessenta, respeitando os limites dos turnos de fala. Cada janela é resumida pelo modelo de linguagem em até oitenta tokens, indicando a intenção, o que foi resolvido e o que ficou pendente. Esse resumo é convertido em um vetor de mil quinhentas e trinta e seis dimensões, normalizado, e gravado no banco vetorial dentro de um namespace exclusivo do cliente, acompanhado dos metadados de canal, intenção, data, situação de resolução e prazo de expiração.

No caminho de leitura, executado a cada mensagem recebida, a consulta é convertida em vetor pelo mesmo modelo de embedding, o que garante que consulta e memória vivam no mesmo espaço vetorial. A busca por similaridade de cosseno retorna vinte candidatos, que passam por um filtro obrigatório pelo identificador do cliente e por filtros opcionais de janela temporal, canal e intenção. Um reordenador do tipo cross-encoder reduz os vinte candidatos aos oito mais relevantes de fato, e o bloco final é montado com limite de mil e duzentos tokens, sempre com a data de cada trecho, para que o modelo saiba distinguir o que é recente do que é antigo.

O isolamento por namespace é a garantia técnica de que a busca jamais retornará trecho de outro titular, o que é ao mesmo tempo um requisito de qualidade e um requisito de privacidade. O prazo de expiração gravado em cada vetor é o mecanismo que faz a retenção acontecer sem intervenção manual.

Figura 4 | Memória semântica: como o contexto é gravado e recuperado

Detalhamento do que a Sprint 2 citou apenas como 'LLM + Vector DB + embeddings'.




Figura 4: caminhos de escrita e de leitura da memória semântica, com parâmetros e orçamento de latência.

4.5 Justificativa

O contrato de API é o que transforma a proposta de camada de orquestração em algo que a Claro pode adotar de forma incremental. O argumento central da solução, desde a Sprint 1, é que os squads continuam autônomos e passam a consumir capacidades comuns. Esse argumento só se sustenta se existir uma interface publicada e estável para consumir. Sem endpoint, payload e contrato de erro, o SDK compartilhado é uma promessa.

O modelo de dados responde a uma segunda ordem de exigência. Ele torna possível estimar volume e custo de armazenamento, define onde o dado pessoal vive e, principalmente, permite escrever as regras de retenção e exclusão da LGPD de forma executável, e não como declaração de intenção. E o detalhamento da memória semântica responde ao ponto mais sensível da proposta: a memória é o diferencial do ClaroIntelligence, de modo que explicá-la com parâmetros concretos é o que separa a proposta de uma menção genérica a inteligência artificial.

5. Melhoria 3: segurança, privacidade e conformidade com a LGPD

5.1 Antes

A Sprint 2 não trouxe capítulo de segurança. A privacidade aparecia de forma indireta, na ideia de que o histórico do cliente seria reaproveitado entre canais, sem que se dissesse com que base legal esse reaproveitamento aconteceria, por quanto tempo o dado ficaria guardado, como seria protegido, quem poderia acessá-lo e como o titular exerceria seus direitos. Para uma solução cuja proposta de valor é justamente acumular memória de conversas de milhões de clientes, essa era a lacuna mais grave da entrega.

5.2 Depois

A solução passou a tratar privacidade como parte da arquitetura e não como anexo jurídico. A Figura 5 organiza o ciclo de vida do dado pessoal em seis etapas, da coleta à exclusão, indicando em cada uma a base legal aplicada, o controle técnico correspondente e o prazo. O mesmo quadro apresenta a matriz de controle de acesso por papel e o fluxo de atendimento aos direitos do titular.

Base legal e consentimento

A solução opera com duas bases legais distintas e não as mistura. O tratamento necessário à execução do contrato, previsto no artigo 7, inciso V da LGPD, cobre os dados de serviço: fatura, plano, chamado técnico e cadastro. Já a memória semântica entre canais, que é o que permite reconhecer o cliente e retomar uma conversa anterior, depende de consentimento específico, previsto no artigo 7, inciso I. O consentimento é registrado por finalidade, com versão da política, data e canal de coleta, e pode ser revogado a qualquer momento pelo próprio chat. Revogado o consentimento, o ClaroMemory é desligado para aquele cliente e o sistema volta a operar sem contexto histórico, sem que isso impeça o atendimento.

Criptografia e pseudonimização

Todo tráfego usa TLS 1.3 e a comunicação entre serviços internos usa TLS mútuo. Em repouso, o conteúdo das mensagens e os identificadores externos do cliente são cifrados com AES-256-GCM, com chaves guardadas em cofre gerenciado e rotação a cada noventa dias. O CPF nunca é armazenado em texto: é guardado apenas como resumo criptográfico com sal, suficiente para correlacionar identidades sem permitir a leitura do número. Antes de qualquer conteúdo sair do domínio da aplicação em direção ao modelo de linguagem, ele passa pela etapa de remoção de dados pessoais descrita no capítulo 4, de modo que o provedor de LLM recebe apenas resumo pseudonimizado, sob contrato de retenção zero.

Retenção e exclusão

Os prazos são definidos por finalidade e não por conveniência técnica. A transcrição integral da conversa é mantida por doze meses; a memória semântica pseudonimizada, por vinte e quatro meses, controlada pelo campo de expiração gravado em cada vetor; o histórico agregado de jornada, por trinta e seis meses; e a trilha de auditoria de acesso a dado pessoal, por cinco anos, por exigência de prestação de contas. Um processo diário remove os registros vencidos. O pedido de exclusão do titular produz efeito lógico imediato, com purga física em até quinze dias e emissão de comprovante ao cliente.


Controle de acesso

O acesso ao dado é definido por papel e não por pessoa. O atendente humano enxerga a conversa apenas da sessão que assumiu e vê o dado cadastral mascarado. O analista de

experiência do cliente trabalha com resumos e métricas, sem acesso a transcrição. O time de produto configura personas e regras, sem acesso a conteúdo. A engenharia acompanha métricas agregadas. Somente o encarregado de proteção de dados acessa conversa integral, e ainda assim mediante justificativa registrada. Todo acesso a dado pessoal gera registro imutável na trilha de auditoria, com ator, papel, recurso, operação e base legal invocada.

Figura 5 | Ciclo de vida do dado pessoal e controles de LGPD

Cada etapa indica a base legal aplicada, o controle técnico e o prazo. Papéis e permissões no quadro inferior.



Controle de acesso baseado em papéis (RBAC) aplicado ao Painel Administrativo e as APIs internas

PAPEL	Conversa integral	Resumo semântico	Dado cadastral	Métricas agregadas	Config. de personas	Exportar / excluir
Atendente humano	Somente da sessão ativa	Sim	Mascarado	Não	Não	Não
Analista de CX	Não	Sim	Não	Sim	Não	Não
Product Owner	Não	Não	Não	Sim	Sim	Não
Engenharia (SRE)	Não	Não	Não	Sim	Não	Não
Encarregado (DPO)	Com justificativa	Sim	Sim	Sim	Não	Sim

Atendimento aos direitos do titular - fluxo automatizado no próprio canal conversacional					
Confirmar tratamento	resposta imediata no chat	Acessar dados	JSON assinado em até 24 h	Corrigir	abre ordem de correção
Anonimizar / eliminar	purga em até 15 dias	Revogar consentimento	efeito imediato, memória desligada	Informar compartilhamento	lista de operadores

Figura 5: ciclo de vida do dado pessoal, matriz de acesso por papel e atendimento aos direitos do titular.

5.3 Justificativa

Uma solução que propõe memória persistente de conversas em uma operadora com dezenas de milhões de clientes não passa por nenhuma avaliação séria de viabilidade sem tratar privacidade de forma explícita. A observação da banca antecipou exatamente a primeira pergunta que qualquer área de compliance faria, e responder a ela depois seria caro: controles como pseudonimização, isolamento por namespace e separação entre texto integral e resumo vetorizado precisam estar no desenho do dado desde o início, porque reconstruí-los depois significa reprocessar toda a base.

Há também um efeito sobre a confiança do cliente, que é o próprio objetivo do projeto. A proposta pede ao cliente que aceite ser reconhecido entre canais. Esse acordo só se sustenta se vier acompanhado de controle real: consentimento granular, revogação simples e exclusão com prazo. Tratar isso como parte da experiência, e não como letra miúda, é coerente com a tese central da solução.

6. Melhoria 4: requisitos formais e métricas objetivas

6.1 Antes

A Sprint 2 descrevia funcionalidades em texto corrido e em tabelas de componentes, sem numeração, sem prioridade, sem critério de aceite e sem separação entre requisito funcional e requisito não funcional. As métricas apresentadas eram de resultado de negócio, como FCR, CES e taxa de transbordo, todas relevantes, porém nenhuma delas descrevia o comportamento esperado do sistema em operação. Não havia meta de tempo de resposta, de disponibilidade, de taxa de erro nem de volume de usuários simultâneos. Sem isso, não é possível dimensionar infraestrutura, escrever teste de carga nem definir quando a solução está pronta.

6.2 Depois: requisitos funcionais

Foram formalizados vinte requisitos funcionais, numerados de RF01 a RF20, cada um com prioridade e com o status atual no protótipo. A numeração é a mesma usada no backlog de cenários do Anexo C, o que permite rastrear cada requisito até o cenário de teste que o valida.

Tabela 5: requisitos funcionais do ClaroIntelligence.

ID	Requisito funcional	Prioridade	Status no protótipo
RF01	Identificar o cliente de forma única a partir de qualquer canal, consolidando CPF, telefone, identificador do aplicativo e contrato.	Alta	Implementado
RF02	Recuperar o contexto semântico das interações anteriores do cliente antes de gerar a resposta.	Alta	Implementado
RF03	Permitir que uma jornada iniciada em um canal continue em outro sem repetição de informações.	Alta	Implementado
RF04	Classificar a intenção de cada mensagem e registrar o nível de confiança da classificação.	Alta	Implementado
RF05	Adaptar tom, vocabulário e nível de detalhe da resposta ao perfil comportamental do cliente.	Média	Parcial
RF06	Detectar sinais de atrito durante a conversa e calcular um score por turno.	Alta	Parcial
RF07	Acionar intervenção proativa quando o score de atrito ultrapassar o limiar configurado.	Alta	Parcial
RF08	Transferir a conversa para atendimento humano preservando todo o histórico e o contexto.	Alta	Parcial
RF09	Gravar cada turno como memória semântica pseudonimizada, com prazo de expiração.	Alta	Implementado
RF10	Consultar fatura em aberto e emitir a segunda via com código de barras e linha digitável.	Alta	Implementado
RF11	Consultar o plano contratado e simular alteração de plano.	Média	Parcial
RF12	Abrir, consultar e acompanhar chamado técnico com número de protocolo.	Alta	Parcial
RF13	Executar diagnóstico remoto de conexão e apresentar o resultado em linguagem simples.	Média	Conceitual
RF14	Agendar, reagendar e cancelar visita técnica.	Média	Conceitual
RF15	Registrar contestação de cobrança e acompanhar o andamento.	Média	Conceitual
RF16	Registrar e revogar consentimento por finalidade, com versionamento da política.	Alta	Conceitual
RF17	Atender pedidos de acesso, correção, portabilidade e exclusão de dados pessoais.	Alta	Conceitual
RF18	Exibir dashboard de jornada com volume, FCR, CES e transbordo.	Alta	Implementado
RF19	Exibir mapa de atrito por jornada e por etapa, com alerta quando o limiar for ultrapassado.	Alta	Implementado
RF20	Configurar personas, limiares de atrito e regras de roteamento pelo painel, sem nova liberação de código.	Média	Parcial
RF21	Recuperar o portfólio contratado pelo titular, com contas, contratos e assinaturas ativas, em todas as linhas de produto.	Alta	Parcial
RF22	Desambiguar a qual produto a mensagem se refere quando o titular possui mais de um produto elegível para a	Alta	Parcial

ID	Requisito funcional	Prioridade	Status no protótipo
	intenção.		
RF23	Verificar, antes de agir, se a intenção detectada é suportada pelo produto em foco, usando a matriz de capacidades.	Alta	Parcial
RF24	Rotear a chamada para o adaptador da linha de produto correspondente, traduzindo para o contrato do sistema de origem.	Alta	Parcial
RF25	Registrar a assinatura de produto em foco na sessão e reaproveitá-la na memória semântica, evitando perguntar de novo.	Alta	Parcial
RF26	Manter um catálogo de produtos versionado, com linha, família, capacidades, adaptador e tempo limite de consulta.	Alta	Parcial
RF27	Atender titular pessoa jurídica, resolvendo CNPJ, múltiplos contratos por site e rateio por centro de custo.	Média	Conceitual
RF28	Reconhecer combos convergentes, como o Claro Multi, apresentando fatura única sem perder a identidade de cada contrato.	Média	Conceitual

6.3 Depois: requisitos não funcionais e métricas de desempenho

Foram formalizados quatorze requisitos não funcionais, cada um com métrica objetiva, meta numérica e o método de medição. A meta de tempo de resposta é expressa em percentis, e não em média, porque a média esconde a cauda que é justamente onde o cliente desiste. As metas de volume distinguem a fase piloto do cenário de produção, para que o dimensionamento acompanhe a estratégia incremental defendida desde a Sprint 1.

Tabela 6: requisitos não funcionais, com métricas objetivas e método de medição.

ID	Requisito não funcional	Métrica objetiva e meta	Como será medido
RNF01	Tempo de resposta percebido	p95 de 2,0 s e p99 de 3,5 s até o primeiro token; p95 de 6,0 s para a resposta completa.	Histograma de latência por endpoint no OpenTelemetry.
RNF02	Disponibilidade do serviço	99,9% ao mês, o que equivale a 43 minutos de indisponibilidade.	Sonda sintética a cada 60 s em três regiões.
RNF03	Taxa de erro	Menos de 0,5% de respostas com erro 5xx e menos de 2% de respostas sem contexto por degradação.	Razão entre erros e total de requisições, janela de 5 minutos.
RNF04	Volume de usuários simultâneos	3.000 sessões simultâneas no piloto e 25.000 no cenário de produção, com pico de 150 mensagens por segundo.	Teste de carga com k6 antes de cada liberação.
RNF05	Escalabilidade horizontal	Dobrar a capacidade em até 5 minutos, com autoescala disparada pelo tamanho da fila.	Ensaio de escala em ambiente de homologação.
RNF06	Latência da memória semântica	Recuperação com p95 de 250 ms; gravação assíncrona concluída em até 1 s.	Métrica dedicada por chamada ao Vector Database.
RNF07	Segurança da aplicação	TLS 1.3 em trânsito, AES-256-GCM em repouso e conformidade com OWASP ASVS nível 2.	Varredura automatizada e teste de intrusão semestral.
RNF08	Privacidade e direitos do titular	Exclusão concluída em até 15 dias e portabilidade entregue em até 24 horas.	Relatório mensal de pedidos e prazos.
RNF09	Observabilidade	100% das interações com trace_id ponta a ponta e retenção de métricas por 13 meses.	Auditoria de amostragem no Grafana.
RNF10	Custo por sessão	Custo médio de até R\$ 0,18 por sessão, somando tokens de LLM e infraestrutura.	Rateio mensal por etiqueta de custo na nuvem.
RNF11	Usabilidade do painel	Uso pleno em resolução de 1366 por 768 e conformidade com WCAG 2.1 nível AA.	Checklist de acessibilidade e teste com cinco usuários internos.
RNF12	Portabilidade de modelo	Troca do provedor de LLM sem alteração no núcleo, apenas por configuração.	Ensaio de troca entre dois provedores a cada trimestre.
RNF13	Manutenibilidade	Cobertura de testes de no mínimo 80% no núcleo e contrato OpenAPI versionado em SemVer.	Relatório de cobertura no pipeline de integração contínua.
RNF14	Continuidade	RPO de 15 minutos e RTO de 1 hora.	Simulação de recuperação a cada semestre.

6.4 Justificativa

Requisito não escrito é requisito não cobrável. A formalização em RF e RNF cria a base contratual da entrega: define o que o sistema deve fazer, com que qualidade, e como isso será verificado. Para o projeto, o efeito imediato foi tornar o backlog planejável, já que cada requisito tem prioridade e status.

As métricas objetivas de desempenho respondem a uma pergunta prática que a banca fez de forma direta. Um assistente conversacional que demora oito segundos para responder não é usado, por melhor que seja a resposta. Ao fixar dois segundos no percentil noventa e cinco até o primeiro token, o projeto passou a ter um orçamento de latência que se distribui pelos componentes, e foi justamente esse orçamento que motivou decisões de arquitetura como a assincronia da gravação de memória e o limite de duzentos e cinquenta milissegundos para a recuperação de contexto. Métrica de desempenho, aqui, não é burocracia: é o que determinou o desenho.

7. Melhoria 5: experiência conversacional, fluxogramas e protótipo visual

7.1 Antes e a ampliação dos cenários

A Sprint 2 apresentou dois cenários conversacionais, ambos bem construídos: a continuidade de uma jornada de suporte técnico entre o site e o WhatsApp e a detecção de frustração em uma cobrança indevida. A banca observou, com razão, que a jornada real de um cliente de telecom é bem mais ampla, e sugeriu que os cenários fossem transformados em tarefas de desenvolvimento e em base de teste.

A sugestão foi adotada integralmente. O catálogo passou de dois para vinte e seis cenários, agrupados em sete jornadas: faturamento, comercial, suporte, atendimento, retenção, privacidade e corporativo. Cada cenário recebeu identificador, prioridade, critério de aceite resumido e status atual, o que o torna simultaneamente um item de backlog e um caso de teste. O Anexo C traz o catálogo completo. Os cenários cobrem, entre outros, os itens citados na sugestão: consultar fatura, emitir segunda via, consultar e alterar plano, reportar problema técnico, reagendar visita técnica e solicitar atendente humano.

7.2 Antes e depois dos fluxogramas

Na Sprint 2, os fluxos foram apresentados como transcrição de diálogo em texto corrido. O formato comunica bem a intenção de produto, mas não mostra decisões, condições, responsáveis nem caminhos de exceção, e a leitura fica pesada, como a banca apontou.

Figura 6A | ANTES (Sprint 2)

O fluxo da jornada era apresentado como transcrição de diálogo em texto corrido, sem decisões, sem condições e sem responsáveis.





Figura 6A: fluxo apresentado como transcrição de diálogo na Sprint 2.

A notação foi trocada por fluxograma em raia, no estilo BPMN simplificado. Cada raia identifica um responsável: o cliente, o canal, o núcleo de orquestração, o ClaroSense e os sistemas da Claro. Losangos marcam as decisões, com as condições escritas nas setas, e os caminhos de exceção deixaram de estar implícitos no texto. A Figura 6B traz a jornada de segunda via de

fatura nesse formato; cada um dos vinte e seis cenários do Anexo C possui um fluxograma equivalente, versionado junto ao código do protótipo.

Figura 6B | DEPOIS (Sprint 4) - Fluxograma da jornada 'segunda via de fatura' em raias (BPMN simplificado)

Mesma jornada, agora com responsáveis, pontos de decisão, condições explícitas e caminhos de exceção. Uma figura por cenário, no Anexo C.



Cada uma das 18 jornadas mapeadas no Anexo C possui um fluxograma equivalente, versionado junto ao código do protótipo.

Figura 6B: jornada de segunda via de fatura em notação de raias, com decisões e caminhos de exceção.

7.3 Antes e depois da interface administrativa

A interface administrativa foi descrita na Sprint 2 apenas como uma tabela de oito funcionalidades, com descrição e usuário interno. Não havia tela, wireframe nem qualquer representação visual, o que impedia discutir hierarquia de informação, fluxo de trabalho do analista e prioridade de construção.

Figura 7A | ANTES (Sprint 2)

A interface administrativa existia apenas como tabela de funcionalidades. Nenhuma tela, wireframe ou protótipo visual.

Funcionalidade	Descrição	Usuário Interno
Dashboard de Jornada	Exibe principais jornadas, volume e status	CX / Produto
Mapa de Atrito	Mostra onde os clientes mais demonstram frustracao	CX
Monitor de Conversas	Permite visualizar interacoes críticas	Atendimento
Gestão de Personas	Ajusta perfis de comunicação por segmento	Produto / UX
Regras de Roteamento	Define quando transferir para humano ou outro canal	Operações
Métricas de Transbordo	Mede quantos atendimentos digitais viraram ligação	Gestão
Acompanhamento de FCR	Mede resolução no primeiro contato	CX / Operações
Log de Intervenções	Registra ações automaticas do ClaroSense	Tecnologia

Figura 7A: interface administrativa como tabela de funcionalidades na Sprint 2.

Foram produzidos wireframes de média fidelidade das três telas centrais. O Dashboard de Jornada reúne os indicadores de sessões ativas, FCR, CES e transbordo, a série de sessões por hora e o ranking de jornadas por volume. O Mapa de Atrito apresenta a matriz de jornada por etapa, com destaque para as células acima do limiar e um bloco de alerta que traduz o número em ação sugerida. O Monitor de Conversas mostra a fila de sessões críticas, a conversa com os eventos do ClaroSense embutidos na linha do tempo e o botão que permite ao atendente humano assumir a conversa. As duas primeiras telas já existem no protótipo; a terceira está especificada e em construção, e o wireframe indica isso de forma explícita.

Figura 7B | DEPOIS (Sprint 4) - Wireframes de média fidelidade do Painel Administrativo

Telas 1 e 2 já implementadas no protótipo. Tela 3 especificada e em construção. Dados exibidos são fictícios, para fins de layout.




Figura 7B: wireframes de média fidelidade das três telas centrais do Painel Administrativo.

7.4 Justificativa

Transformar cenário em backlog resolve três problemas de uma vez. Dá visibilidade de progresso, porque o avanço passa a ser medido em cenários concluídos e não em percentual estimado. Cria a base de teste, já que cada cenário carrega seu critério de aceite. E força o time a enfrentar cedo os casos difíceis, como cancelamento com retenção e exercício de direitos de privacidade, que costumam ficar para o fim justamente por serem os mais delicados.

A troca da notação dos fluxogramas atende ao pedido de legibilidade, mas tem um ganho maior: a transcrição de diálogo descreve o caminho feliz, enquanto o fluxograma em raias obriga a explicitar o que acontece quando o cliente não é identificado, quando o sistema legado não responde e quando o cliente não confirma a resolução. São esses caminhos que determinam a qualidade real percebida.

Os wireframes, por fim, deslocam a discussão do que o painel faz para como o analista trabalha nele. Foi ao desenhar o Mapa de Atrito que ficou claro que o número isolado não gera ação, e daí surgiu o bloco de alerta com ação sugerida. Interface desenhada revela requisito que interface descrita esconde.

8. Melhoria 6: integração dos diferentes produtos da Claro

8.1 Antes e o questionamento da Claro

Durante a banca de apresentação, a própria equipe da Claro levantou um ponto que nenhuma das entregas anteriores havia enfrentado. A solução tratava a fragmentação como um problema de canais: site, aplicativo, WhatsApp, chatbot e call center. Mas a Claro não vende um serviço, vende um portfólio. O mesmo titular pode ter banda larga fixa, uma ou mais linhas móveis, TV por assinatura, telefonia fixa e, no caso corporativo, links dedicados, nuvem e dispositivos conectados. A pergunta foi direta: além dos canais, como a solução vai integrar os diferentes produtos?

A Sprint 2 assumia implicitamente um cliente com um produto só. Os dois cenários apresentados eram de suporte técnico de internet residencial e de contestação de fatura, sem que se dissesse de qual fatura. O diagrama de arquitetura terminava em blocos genéricos chamados Billing, CRM e OSS, como se existisse um único sistema de faturamento para toda a operadora. O modelo de dados tinha uma entidade cliente ligada diretamente a sessão, sem nada entre elas que representasse conta, contrato ou assinatura de produto. Na prática, a solução respondia bem à pergunta por onde o cliente falou e não tinha resposta para a pergunta sobre o que ele falou.

Por que isso é um problema real, e não teórico

O cliente escreve minha internet caiu. Isso pode ser a fibra da casa, o acesso fixo sem fio 5G, a franquia de dados do celular ou a conexão do Box de TV. São quatro produtos, quatro sistemas de origem e quatro diagnósticos diferentes. Se o assistente errar o produto, ele executa a ação certa no contrato errado, o que é pior do que não responder.

8.2 Depois: o portfólio mapeado

O primeiro passo foi levantar o portfólio real que a Claro oferece ao cliente final, em 2026, nas duas frentes. Na pessoa física e residencial, isso inclui a telefonia móvel em quatro modalidades comerciais, a banda larga fixa em fibra e no cabo coaxial legado, a TV por assinatura em cinco formas de entrega distintas, a telefonia fixa, os combos convergentes e uma faixa larga de serviços de valor agregado. Na frente empresarial, unificada sob a marca Claro Empresas desde abril de 2025, o portfólio vai de conectividade dedicada e redes privadas a nuvem, data center, cibersegurança e comunicação corporativa.

Três constatações desse levantamento mudaram o desenho da solução. A primeira é que a consolidação de marcas não significou consolidação de sistemas: por trás de uma fachada única convivem plataformas herdadas da Claro móvel, da Net no residencial, da Embratel no corporativo e da Nextel na base legada. A segunda é que cada linha de produto tem uma chave de identificação diferente. No móvel a chave é a linha; no residencial é o ponto de instalação, ou seja, o endereço, e não o CPF, de modo que o mesmo titular com duas casas tem dois contratos distintos; na TV a assinatura pode estar vinculada ao CPF ou ao ponto; no corporativo a chave é o CNPJ, com múltiplos contratos por site e rateio por centro de custo. A terceira é que a convergência já é o caso majoritário e não a exceção, com a base que combina móvel e residencial crescendo mais de catorze por cento ao ano, o que torna a ambiguidade de produto a regra, e não um caso de borda.

Figura 8 | Mapa do portfólio da Claro e chaves de identificação por linha de produto

Levantamento das ofertas ao cliente final em 2026. O ClaroIntelligence precisa reconhecer o cliente e o produto sobre o qual ele fala, não apenas o canal.




Figura 8: mapa do portfólio da Claro ao cliente final e as chaves de identificação de cada linha de produto.

Tabela 7: portfólio da Claro, chaves de identificação, sistemas de origem e cobertura atual no protótipo.

Linha de produto	Ofertas ao cliente final	Chave de identificação	Sistema de origem	Jornadas mais frequentes	Cobertura no protótipo
Móvel	Prezão (pré-pago), Claro Controle, Claro Pós e Max, Claro Flex, Claro nxt, 5G+, eSIM, Passaporte (roaming), Claro Sync.	Linha (MSISDN) sob uma conta de faturamento	BSS Móvel	Recarga e saldo, fatura e segunda via, franquia e consumo, troca de plano, portabilidade.	Adaptador contra simulador
Banda larga fixa	Claro fibra (FTTH), Net Virtua (HFC legado), FWA 5G, internet via satélite, Wi-Fi 6 e 7, mesh e ponto adicional.	Ponto de instalação (endereço)	BSS Residencial	Diagnóstico remoto, upgrade de velocidade, visita técnica, mudança de endereço, fatura.	Adaptador contra simulador
TV e vídeo	Claro tv+ App, Box e Soundbox, cabo e satélite em 4K, Claro tv pré-pago, streamings agregados (Netflix, Max, Disney+, Globoplay).	Assinatura vinculada ao CPF ou ao ponto	Plataforma Claro tv+	Falha de sinal, ponto adicional, add-on de streaming, troca de pacote, fatura.	Adaptador contra simulador
Telefonia fixa	Planos com ligações ilimitadas por cabo, Claro net fone (VoIP) ou tecnologia por chip.	Ponto de instalação	BSS Residencial	Portabilidade de número, falha de linha, fatura.	Conceitual
Combos convergentes	Claro Multi: fibra, móvel e Claro tv+ com desconto e fatura única.	Titular, com contratos que permanecem separados	Consolidação sobre os BSS	Fatura única, desconto, gestão dos serviços do combo.	Conceitual
Serviços de valor agregado	Claro Assist, Smarthome, Proteção Digital, Gaming, música, Claro Clube, smartcred, seguros.	Assinatura vinculada ao CPF	Plataformas de parceiros	Ativação e cancelamento de assinatura, suporte ao serviço.	Conceitual
Claro Empresas: conectividade	Fibra empresarial, internet e link dedicado, SD-WAN, MPLS, redes privadas 5G e 4G, IPSat e satélite.	CNPJ, com contrato por site e centro de custo	BSS Claro Empresas (ex-Embratel)	Chamado com SLA, upgrade de banda, janela de manutenção, fatura por CNPJ.	Conceitual
Claro Empresas: móvel e IoT	Pós corporativo, Claro Total Compartilhado, Claro IoT, M2M, NB-IoT e LTE-M, gestão de mobilidade.	CNPJ e identificador do dispositivo	Plataforma IoT e BSS Móvel	Gestão de parque de linhas, consumo compartilhado, ativação de SIM, status do dispositivo.	Conceitual
Claro Empresas: cloud e segurança	Claro Cloud e multicloud, data center e colocation, Claro Monitor, EDR, WAF, backup e serviços gerenciados.	CNPJ e contrato de serviço	BSS Claro Empresas	Abertura de incidente, relatório de disponibilidade, faturamento por consumo.	Conceitual
Claro Empresas: comunicação	PABX virtual, 0800, VoIP, Atendimento Fácil, Blip Go, Microsoft 365, Google Workspace, Claro tv Empresarial.	CNPJ	BSS Claro Empresas	Configuração de ramal, falha de voz, licenças, fatura.	Conceitual

8.3 Depois: a camada de contexto de produto

A solução ganhou um componente novo no núcleo de orquestração, o Product Context Resolver, executado logo após o Unified Customer ID. A separação é deliberada: o Unified Customer ID responde quem é o titular, e o novo componente responde sobre qual produto dele a conversa trata. São dois eixos independentes, e tratá-los como um só foi exatamente o erro da Sprint 2.

O resolvidor opera em cinco etapas. Consolida as identidades do titular, incluindo CPF ou CNPJ, linha, identificador do aplicativo, ponto de instalação e número de contrato. Consulta o portfólio ativo em cada sistema de origem, com cache de quinze minutos para não penalizar o tempo de resposta. Desambigua o produto: quando só existe um elegível para a intenção detectada, segue direto; quando existem vários, usa o canal de entrada, o histórico recente e a última interação para inferir, e só faz uma pergunta ao cliente se a inferência não for confiável. Verifica, na matriz de capacidades, se aquela intenção é suportada por aquele produto. E, por fim, seleciona o adaptador da linha de produto e monta a chamada no contrato do sistema correspondente.

Os adaptadores são a peça que impede a solução de virar um emaranhado de casos particulares. Cada linha de produto tem o seu, e cada um traduz o contrato do sistema de origem para um contrato interno único. O núcleo pede fatura em aberto; o adaptador do móvel resolve isso de um jeito, o do residencial de outro, o de TV de um terceiro, e o núcleo não precisa saber a diferença. Foi assim que a camada anticorrupção descrita na Melhoria 1 deixou de ser um bloco genérico e passou a ter cinco implementações nomeadas.

Figura 9 | Camada de contexto de produto: como uma única conversa alcança todo o portfólio

O canal diz por onde o cliente falou. O produto diz sobre o que ele falou. São dois eixos independentes e a solução precisa resolver os dois.




Figura 9: camada de contexto de produto, com o resolutor em cinco etapas e os adaptadores por linha de produto.

8.4 Depois: extensão do modelo de dados

O modelo de dados da Figura 3 ligava cliente diretamente a sessão. Isso funcionava enquanto o cliente tinha um produto. Foram acrescentadas seis entidades entre os dois, e a mudança é estrutural.

- A conta de faturamento separa o titular da cobrança, porque um mesmo titular pode ter várias contas, com ciclos diferentes, e o Claro Multi consolida a cobrança sem fundir os contratos.
- O ponto de instalação representa o endereço, que é a chave real dos produtos residenciais. Sem ele, dois contratos de fibra do mesmo titular seriam indistinguíveis.
- O contrato liga a conta a uma linha de negócio e carrega o campo que aponta para qual sistema de origem responde por ele, o que é o que permite escolher o adaptador.
- A assinatura de produto é a menor unidade que o cliente reconhece: uma linha, um ponto de TV, um link dedicado. É sobre ela que o cliente fala.
- O catálogo de produtos é a fonte única de verdade do portfólio, com código estável independente do nome comercial, que muda com campanha.
- A capacidade de produto é a matriz que diz quais intenções cada produto suporta, e o que fazer quando não suporta.

Duas entidades que já existiam foram estendidas. A sessão passou a guardar a assinatura de produto em foco, junto com a marcação de que o produto foi confirmado, o que evita perguntar de novo a cada turno. E a intenção deixou de ser um código isolado e passou a ser um par de intenção e produto, com o seu próprio nível de confiança. Essa mudança se propaga para a memória semântica: os metadados de cada vetor passaram a incluir o código do produto, de modo que a recuperação de contexto pode ser filtrada pelo produto em questão. Sem isso, uma conversa antiga sobre a fatura do celular poderia ser trazida como contexto de uma pergunta sobre a fatura da TV.

Figura 10 | Extensão multiproduto do modelo de dados

Seis entidades novas que se ligam ao modelo da Figura 3. Elas separam titular, conta, contrato, ponto de instalação e assinatura de produto.




Figura 10: extensão multiproduto do modelo de dados, com conta, ponto de instalação, contrato, assinatura, catálogo e capacidades.

8.5 Depois: reflexo nas APIs, nos requisitos e nos cenários

A mudança não ficou no diagrama. Quatro rotas novas entraram no contrato da API: a consulta do portfólio contratado pelo titular, a fixação do produto em foco na sessão, a leitura do catálogo de produtos e a leitura da matriz de capacidades. Três códigos de erro novos foram padronizados, e eles descrevem exatamente os modos de falha que o multiproduto introduz: produto ambíguo, quando há mais de um elegível e o canal precisa exibir a pergunta de desambiguação; produto não contratado, quando a intenção se refere a algo que o titular não possui; e capacidade não suportada, quando a intenção existe mas não se aplica àquele produto.

Do lado dos requisitos, foram acrescentados oito requisitos funcionais, de RF21 a RF28, cobrindo recuperação de portfólio, desambiguação, verificação de capacidade, roteamento por adaptador, persistência do produto em foco, catálogo versionado, atendimento a titular pessoa jurídica e tratamento de combos convergentes. E o catálogo de cenários cresceu de dezoito para vinte e seis, com uma coluna nova que declara a linha de produto de cada um. Os oito cenários acrescentados são justamente os que não existiriam em uma solução de produto único: recarga de linha pré-paga, ativação de eSIM, add-on de streaming, falha de sinal de TV, mudança de endereço da instalação, gestão de parque de linhas corporativas, chamado com SLA e consulta a dispositivos conectados.

8.6 Justificativa

O questionamento da Claro atingiu o ponto mais frágil da proposta. A tese do ClaroIntelligence é que o cliente deve encontrar uma só Claro. Uma solução que unifica canais mas continua cega ao portfólio entrega apenas metade disso: o cliente deixa de repetir por onde falou, mas continua tendo de explicar sobre o que está falando, e continua sendo mandado para o lugar errado quando erra o vocabulário. Do ponto de vista do cliente, os dois problemas são o mesmo problema.

Há também uma consequência sobre a viabilidade da proposta dentro da Claro. O argumento incremental defendido desde a Sprint 1 é que os squads continuam autônomos e passam a consumir capacidades comuns. Esses squads são organizados por produto, e não por canal. Sem uma camada de produto explícita, com catálogo, capacidades e adaptadores, cada squad precisaria negociar sua própria integração com o núcleo, o que reproduziria exatamente o retrabalho que a solução se propõe a eliminar. O catálogo de produtos é o que permite que um squad adicione um produto novo por configuração, e não por alteração de código no núcleo.

Por fim, o levantamento do portfólio impôs uma dose de realismo que o documento não tinha. Ficou explícito que a operadora convive com sistemas herdados de quatro origens distintas, que boa parte da base de banda larga ainda está no cabo coaxial e não na fibra, e que a integração corporativa depende de contratos com estrutura própria. Reconhecer isso no desenho é o que separa uma arquitetura executável de uma arquitetura que só funciona no slide.

9. Estado atual do protótipo: implementado, parcial e conceitual

Este capítulo responde de forma direta ao feedback de que não estava claro o que já existia e o que era intenção. A classificação usa três níveis. Implementado significa que o item funciona no protótipo e pode ser demonstrado. Parcial significa que existe uma versão reduzida, com escopo declarado. Conceitual significa que existe desenho e especificação, mas não há código em execução. A mesma marcação aparece nas figuras deste documento, de modo que a leitura do diagrama já informa o estágio de cada componente.

Vale registrar o critério que orientou a construção do protótipo. Foram priorizados os componentes que sustentam a tese central da solução, ou seja, a continuidade de contexto entre canais, e adiadas as integrações que dependem de acesso a ambientes da Claro, que não estão disponíveis para o time neste momento e que foram substituídas por simuladores com contrato equivalente.

Tabela 8: matriz de estado atual do protótipo.

Componente ou funcionalidade	Status	Evidência ou próximo passo
Núcleo de orquestração e API de mensagens	Implementado	Serviço em execução, contrato OpenAPI publicado, demonstrado no vídeo.
Unified Customer ID	Implementado	Resolução por CPF, telefone e identificador do aplicativo, com base de teste.
ClaroMemory: gravação de memória semântica	Implementado	Pipeline de chunking, embedding e upsert em execução.
ClaroMemory: recuperação com kNN e filtro	Implementado	Busca por similaridade com filtro obrigatório por cliente.
Continuidade de contexto entre dois canais	Implementado	Cenário site para WhatsApp reproduzido na demonstração.
Intent Router com catálogo de intenções	Implementado	Nove intenções treinadas, com limiar de confiança de 0,70.
Dashboard de Jornada	Implementado	Tela funcional com dados do próprio protótipo.
Mapa de Atrito	Implementado	Matriz por jornada e etapa, com alerta por limiar.
Persona Engine	Parcial	Três perfis fixos configurados; falta o aprendizado contínuo do perfil.
ClaroSense: sinais de atrito	Parcial	Dois dos quatro sinais ativos (repetição de intenção e sentimento).
Intervenção proativa automática	Parcial	Regra de limiar funcionando; falta o catálogo completo de ações.
Monitor de Conversas com assunção por humano	Parcial	Tela especificada e em construção; wireframe na Figura 7B.
Response Composer com guardrails	Parcial	Guardrails de escopo ativos; falta o bloqueio de dados sensíveis na saída.
Integração real com Billing, CRM e OSS da Claro	Conceitual	Hoje há simuladores; depende de acesso aos ambientes da Claro.
Canais WhatsApp, URA e Call Center em produção	Conceitual	Protótipo usa uma interface web que simula os canais.
Event Bus Kafka e Data Lake	Conceitual	Hoje os eventos são gravados no PostgreSQL de forma síncrona.
Trilha de auditoria imutável	Conceitual	Modelo de dados definido; falta a implementação com armazenamento WORM.
Consentimento e fluxo de direitos do titular	Conceitual	Modelo e fluxo desenhados no capítulo 5; sem implementação.
Criptografia em repouso com cofre de chaves	Conceitual	Ambiente de protótipo usa chaves locais de desenvolvimento.
SDK compartilhado para squads	Conceitual	Contrato OpenAPI pronto; geração do SDK prevista para a próxima etapa.
Catálogo de produtos com linha, família e capacidades	Parcial	Catálogo carregado com 14 produtos de referência; falta a carga completa.
Product Context Resolver e desambiguação de produto	Parcial	Resolve o portfólio simulado e desambigua; falta o aprendizado do produto preferido.
Adaptadores de móvel, residencial e TV	Parcial	Três adaptadores contra simuladores, com o contrato interno já definido.

Componente ou funcionalidade	Status	Evidência ou próximo passo
Adaptadores de Claro Empresas e IoT	Conceitual	Contrato desenhado; depende de acesso aos ambientes correspondentes.
Atendimento a titular pessoa jurídica (CNPJ)	Conceitual	Modelo de dados preparado; jornada B2B ainda não implementada.
Fatura única de combo convergente (Claro Multi)	Conceitual	Modelado como consolidação de cobrança sobre contratos que continuam separados.

10. Vídeo de demonstração

O vídeo tem duração entre três e cinco minutos e demonstra as melhorias no sistema funcional, comparando a versão anterior com a versão atual. Toda a equipe aparece em câmera aberta e o link está público.

Acesso ao vídeo

[INSERIR AQUI O LINK PÚBLICO DO VÍDEO]

O roteiro do vídeo segue a ordem das melhorias deste documento:

- Abertura com a equipe e resumo dos feedbacks recebidos.
- Arquitetura: comparação entre o diagrama da Sprint 2 e o diagrama de containers atual, com destaque para protocolos e fluxo de dados.
- APIs e dados: chamada real ao endpoint de mensagens, exibindo o payload de requisição e a resposta com contexto recuperado, intenção e score de atrito.
- Memória semântica: demonstração da continuidade de contexto, iniciando uma jornada em um canal e retomando em outro.
- Multiproduto: a mesma frase sobre uma fatura sendo resolvida para o produto correto, com a desambiguação em ação.
- Painel administrativo: navegação pelo Dashboard de Jornada e pelo Mapa de Atrito, com o alerta de limiar sendo disparado.
- Encerramento com a matriz do capítulo 9, separando o que foi demonstrado do que permanece conceitual.

11. Considerações finais

As seis melhorias desta sprint têm um traço comum: todas transformam intenção em algo verificável. A arquitetura passou a declarar protocolos e tempos limite. A API passou a ter contrato publicado. Os dados passaram a ter entidades, prazos e regras de exclusão. Os requisitos passaram a ter número, meta e método de medição. Os cenários passaram a ter critério de aceite. E o estado do protótipo passou a ser declarado item a item, sem ambiguidade. A sexta melhoria acrescentou a esse conjunto o eixo que faltava: o produto sobre o qual o cliente fala, e não apenas o canal por onde ele fala.

Esse movimento é coerente com o argumento que a solução defende desde a Sprint 1. A proposta do ClaroIntelligence nunca foi substituir canais ou reorganizar squads, e sim oferecer uma camada comum que os times possam consumir de forma incremental. Uma camada comum só é adotável se tiver contrato, garantia de desempenho, regra de privacidade e limite claro do que ela faz. Era exatamente isso que faltava na Sprint 2, e é o que esta entrega passou a apresentar.

Permanece válido o alerta metodológico registrado na Sprint 1: as dores mapeadas partem de uma leitura corporativa e precisam de validação externa com usuários reais antes que qualquer meta absoluta seja assumida. As metas numéricas apresentadas no capítulo 6 são compromissos de engenharia sobre o comportamento do sistema, o que é diferente de projeções de impacto de negócio. Estas últimas continuam dependendo do baseline a ser levantado com dados reais da Claro.

Anexo A. Catálogo de endpoints e payloads

Complemento da Tabela 3. As rotas abaixo completam os exemplos apresentados no capítulo 4. O contrato integral em OpenAPI 3.1 acompanha o repositório do protótipo.

A.1 Abertura de sessão

```
POST /v1/sessions
{
  "canal": "whatsapp",
  "identificador_externo": { "tipo": "msisdn", "valor": "+5511987654321" },
  "id_sessao_anterior": "ses_74be21c9",
  "consentimento_memoria": true
}

201 Created
{
  "id_sessao": "ses_1a0f77d2",
  "id_cliente": "cli_8ad3f1c7",
  "continuidade": {
    "detectada": true,
    "canal_anterior": "site",
    "assunto_pendente": "suporte_tecnico_conexao",
    "encerrada_em": "2026-08-19T13:41:02Z"
  },
  "expira_em": "2026-08-19T14:32:55Z"
}
```

A.2 Gravação de memória semântica

```
POST /v1/memory/records
{
  "id_cliente": "cli_8ad3f1c7",
  "id_mensagem": "msg_5c81d0",
  "canal": "site",
  "intencao": "suporte_tecnico_conexao",
  "resolvida": false,
  "texto": "<conteúdo do turno, já sem dados pessoais>"
}

202 Accepted
{
  "id_vetor": "vec_9f2c",
  "dimensoes": 1536,
  "namespace": "cli_8ad3f1c7",
  "expira_em": "2028-08-19T14:02:11Z",
  "processado_em_ms": 462
}
```

A.3 Mapa de atrito para o painel

```
GET /v1/admin/journeys/friction-map?janela=24h

200 OK
{
  "janela": "24h",
  "limiar": 0.70,
  "etapas": ["entrada","identificacao","diagnostico","acao",
             "confirmacao","encerramento"],
  "jornadas": [
    { "codigo": "contestar_cobranca",
      "scores": [0.22, 0.35, 0.58, 0.81, 0.44, 0.26],
      "alerta": { "etapa": "acao", "score": 0.81,
                  "acao_sugerida": "rotear_especialista_faturamento" } }
  ]
}
```

A.4 Pedido de exclusão de dados do titular

```
POST /v1/privacy/erasure-requests
{
  "id_cliente": "cli_8ad3f1c7",
  "escopo": ["memoria_semantica", "transcricoes"],
  "canal_solicitacao": "whatsapp",
  "confirmacao_titular": true
}

202 Accepted
{
  "id_pedido": "era_66c1e0",
  "status": "em_processamento",
  "exclusao_logica_em": "2026-08-19T14:05:00Z",
  "purga_fisica_prevista": "2026-09-03T00:00:00Z",
  "comprovante_url": "/v1/privacy/erasure-requests/era_66c1e0/receipt"
}
```

A.5 Códigos de erro padronizados

Tabela 4: códigos de erro padronizados devolvidos pela API.

Código HTTP	Código interno	Quando ocorre	Tratamento no canal
400	invalid_payload	Corpo fora do contrato OpenAPI.	Erro de integração; registrar e não repetir.
401	invalid_token	JWT ausente, expirado ou com assinatura inválida.	Renovar o token e repetir uma vez.
403	consent_required	Cliente sem consentimento ativo para uso de memória.	Exibir o pedido de consentimento antes de continuar.
404	session_not_found	Sessão encerrada ou expirada (TTL de 30 minutos).	Abrir nova sessão informando o id anterior.
409	duplicate_message	Mesma chave de idempotência recebida duas vezes.	Tratar como sucesso e usar a resposta original.
422	unsupported_intent	Intenção fora do catálogo de cenários suportados.	Oferecer atendimento humano.

Código HTTP	Código interno	Quando ocorre	Tratamento no canal
429	rate_limited	Limite de requisições por canal excedido.	Aguardar o tempo do cabeçalho Retry-After.
409	product_ambiguous	O titular tem mais de um produto elegível para a intenção detectada.	Exibir a pergunta de desambiguação devolvida no corpo da resposta.
404	product_not_contracted	A intenção se refere a um produto que o titular não possui.	Oferecer a contratação ou corrigir o produto em foco.
501	capability_unsupported	A intenção não é suportada por aquele produto específico.	Usar a ação alternativa indicada no catálogo de produtos.
503	memory_degraded	Vector Database indisponível ou acima do orçamento de latência.	Responder sem memória e sinalizar degradação no painel.

Anexo B. Dicionário de dados

Finalidade, prazo de retenção e tratamento de dado pessoal de cada entidade do modelo apresentado na Figura 3.

Entidade	Finalidade	Retenção	Tratamento de dado pessoal
cliente	Titular do serviço, com identificador interno e atributos de segmentação.	Enquanto durar a relação contratual	CPF armazenado apenas como hash com sal.
identidade_externa	Vínculo entre o cliente e os identificadores usados em cada canal.	Enquanto durar a relação contratual	Valor cifrado com AES-256-GCM.
consentimento	Registro versionado de opt-in e opt-out por finalidade.	5 anos após a revogação	Prova de conformidade; não contém conteúdo de conversa.
perfil_persona	Perfil comportamental usado pela Persona Engine.	12 meses sem interação	Derivado; não contém dado cadastral.
canal	Catálogo de pontos de contato integrados.	Permanente	Não contém dado pessoal.
sessao	Unidade de conversa em um canal, com vínculo à sessão anterior.	12 meses	Contém apenas identificadores.
mensagem	Turno de fala do cliente, do assistente ou do atendente.	12 meses	Texto cifrado em repouso; acesso restrito por RBAC.
intencao	Classificação da mensagem, com confiança e entidades extraídas.	12 meses	Derivado.
memoria_vetorial	Embedding e resumo pseudonimizado usados na recuperação de contexto.	24 meses (campo expira_em)	Resumo sem PII; isolamento por namespace do cliente.
contexto_recuperado	Registro de quais trechos foram usados em cada resposta.	12 meses	Rastreabilidade da decisão do modelo.
sinal_atrito	Sinal individual detectado pelo ClaroSense, com peso.	12 meses	Derivado.
intervencao	Ação proativa executada e seu resultado.	24 meses	Derivado; base para medir eficácia.
historico_jornada	Agregado por cliente e jornada, com FCR, CES e transbordo.	36 meses	Agregado; usado em métricas de CX.
auditoria_acesso	Registro imutável de acesso a dado pessoal.	5 anos	Exigência de prestação de contas da LGPD.
conta_faturamento	Conta de cobrança do titular; um titular pode ter várias.	Enquanto durar a relação contratual	Contém apenas identificadores e ciclo de cobrança.
ponto_instalacao	Endereço de instalação, chave real dos produtos residenciais.	Enquanto durar a relação contratual	Endereço armazenado como hash; texto completo fica no sistema de origem.
contrato	Vínculo comercial entre conta e linha de produto, com o sistema de origem.	5 anos após o cancelamento	Não contém dado pessoal além do vínculo.

Entidade	Finalidade	Retenção	Tratamento de dado pessoal
assinatura_produto	Menor unidade que o cliente reconhece: uma linha, um ponto de TV, um link.	5 anos após o cancelamento	Identificador (MSISDN, ONT) cifrado em repouso.
produto_catalogo	Catálogo de produtos com linha, família, adaptador e SLA.	Permanente	Não contém dado pessoal.
capacidade_produto	Matriz de quais intenções cada produto suporta.	Permanente	Não contém dado pessoal.

Anexo C. Backlog de cenários conversacionais

Vinte e seis cenários derivados das jornadas reais de atendimento, cada um com a linha de produto a que se aplica, prioridade, critério de aceite resumido e status atual. Cada cenário corresponde a um item de backlog e a um caso de teste da solução.

ID	Cenário conversacional	Linha de produto	Jornada	Prio.	Critério de aceite resumido	Status
CN01	Consultar fatura atual	Todas	Faturamento	Alta	O cliente recebe valor, vencimento e status sem informar o contrato.	Implementado
CN02	Emitir segunda via da fatura	Todas	Faturamento	Alta	O cliente recebe linha digitável e PDF em até 2 turnos de conversa.	Implementado
CN03	Contestar cobrança indevida	Todas	Faturamento	Alta	O sistema identifica o item contestado e abre protocolo com número.	Parcial
CN04	Consultar plano contratado	Móvel e residencial	Comercial	Média	O cliente recebe franquia, benefícios e data de renovação.	Implementado
CN05	Alterar plano (subir ou descer)	Móvel	Comercial	Alta	O sistema simula o novo valor e confirma antes de efetivar.	Parcial
CN06	Contratar produto adicional	Todas	Comercial	Média	O cliente conclui a contratação com confirmação explícita.	Conceitual
CN07	Consultar consumo de dados	Móvel	Comercial	Baixa	O cliente recebe o consumo do ciclo atual e a projeção.	Conceitual
CN08	Reportar problema técnico de conexão	Banda larga fixa	Suporte	Alta	O sistema correlaciona com falhas na região antes de pedir dados.	Implementado
CN09	Executar diagnóstico remoto do modem	Banda larga fixa	Suporte	Alta	O diagnóstico roda em segundo plano e o cliente é avisado ao fim.	Parcial
CN10	Agendar visita técnica	Residencial e TV	Suporte	Alta	O cliente escolhe a janela disponível e recebe o protocolo.	Conceitual
CN11	Reagendar ou cancelar visita técnica	Residencial e TV	Suporte	Alta	A alteração é confirmada e a ordem de serviço é atualizada.	Conceitual
CN12	Acompanhar protocolo ou chamado aberto	Todas	Suporte	Média	O cliente informa apenas o assunto e o sistema localiza o protocolo.	Parcial
CN13	Solicitar atendente humano	Todas	Atendimento	Alta	A transferência ocorre com o histórico completo, sem repetição.	Parcial
CN14	Solicitar desbloqueio ou segunda via de chip	Móvel	Atendimento	Baixa	O pedido é registrado e o prazo é informado.	Conceitual
CN15	Alterar dados cadastrais	Todas	Atendimento	Média	A alteração exige autenticação reforçada antes de efetivar.	Conceitual
CN16	Consultar benefícios e programa de fidelidade	Todas	Comercial	Baixa	O cliente recebe saldo e opções de resgate.	Conceitual
CN17	Pedido de cancelamento com retenção	Todas	Retenção	Alta	O ClaroSense identifica o motivo antes de oferecer contraproposta.	Conceitual
CN18	Exercer direitos de LGPD	Todas	Privacidade	Alta	O titular confirma, acessa, corrige ou exclui dados pelo próprio chat.	Conceitual
CN19	Recarregar linha pré-paga e consultar saldo	Móvel pré-pago	Faturamento	Alta	A recarga é concluída no chat, com Pix, e o saldo é confirmado.	Conceitual

ID	Cenário conversacional	Linha de produto	Jornada	Prio.	Critério de aceite resumido	Status
CN20	Ativar eSIM ou trocar de aparelho	Móvel	Atendimento	Média	O QR Code é entregue no canal e a ativação é confirmada.	Conceitual
CN21	Ativar ou cancelar streaming agregado	TV e vídeo	Comercial	Média	O add-on é ativado e a conta do parceiro é vinculada no mesmo fluxo.	Conceitual
CN22	Resolver falha de sinal ou ponto adicional de TV	TV e vídeo	Suporte	Média	O sistema distingue app, box e cabo antes de propor a solução.	Conceitual
CN23	Mudança de endereço da instalação	Residencial	Suporte	Média	O sistema verifica a viabilidade no novo endereço antes de agendar.	Conceitual
CN24	Gerir parque de linhas corporativas	Claro Empresas	Corporativo	Média	O gestor bloqueia, desbloqueia e troca plano de várias linhas do CNPJ.	Conceitual
CN25	Abrir chamado corporativo com SLA	Claro Empresas	Corporativo	Alta	O chamado registra severidade e devolve o prazo contratual do SLA.	Conceitual
CN26	Consultar status de dispositivos IoT	IoT e M2M	Corporativo	Baixa	O cliente recebe o status do parque e o consumo agregado.	Conceitual