

Faculdade de Informática e Administração Paulista

Sistemas de Informação

Guilherme Korus Daoud - RM 97826

Marcos Henrique Ribeiro de Santana - RM 98561

Rafael Jun Miura - RM 98845

Raphael Oliveira Batizati - RM 99949

Sérgio Nogueira - RM 98577

ClaroIntelligence

São Paulo/SP

2026

Sumário Executivo

A Claro enfrenta um desafio estrutural comum a grandes empresas que cresceram rapidamente no digital: múltiplos canais conversacionais como site, aplicativo Minha Claro, três WhatsApps distintos, chatbots e call center que operam com inteligências isoladas, sem continuidade de contexto entre si. Para o cliente, no entanto, é uma só Claro.

Essa fragmentação gera três dores críticas: (1) clientes que repetem informações a cada troca de canal, acumulando esforço e perdendo confiança; (2) transbordo desnecessário para o call center, com custo operacional alto; e (3) squads que replicam integrações idênticas por falta de componentes compartilhados, reduzindo a velocidade de entrega.

SOLUÇÃO

O ClaroIntelligence é uma camada de orquestração com IA que atua sobre os canais existentes sem substituí-los. Três componentes complementares: ClaroMemory, Persona Engine e ClaroSense, garantem que o cliente seja reconhecido, compreendido e atendido de forma proativa, independentemente do canal.

A proposta responde diretamente às expectativas levantadas no kick-off: viabilidade técnica, priorização de investimentos, estratégia incremental e ROI mensurável. Cada camada entrega valor de forma independente e pode ser implementada em sprints progressivos.

1. Contexto e Diagnóstico do Problema

1.1 A Claro em números

A Claro é uma das maiores operadoras de telecom da América do Sul, pertencente ao grupo América Móvil. Só em 2024, registrou 3,4 milhões de transações de venda e mais de 25 bilhões de hits em suas mais de 2.000 APIs. Esse volume coloca a empresa num patamar raro: a escala de uma grande corporação com o alcance direto ao cliente de uma startup.

Esse crescimento acelerado, no entanto, veio com um custo: diferentes times desenvolveram soluções digitais em velocidades e maturidades distintas, criando um ecossistema fragmentado de canais que, do ponto de vista do cliente, deveria ser uma experiência única e coesa.

1.2 As três dores centrais

Dor	Manifestação concreta	Impacto
Fragmentação de canais	Três WhatsApps distintos (e-commerce, atendimento, suporte) sem acesso ao contexto uns dos outros. Cliente não sabe qual resolve.	Baixa resolutividade, aumento de esforço (CES alto)
Repetição de informações	Cliente preenche dados num canal, é redirecionado e recomeça do zero. Sensação de 'será que estou na Claro mesmo?'	Perda de credibilidade, abandono de jornada
Retrabalho entre squads	Três squads quase fizeram integrações idênticas com a mesma ferramenta de pesquisa. Falta de componentes compartilhados.	Time-to-market lento, custo operacional elevado

ALERTA

Como ressaltado no kick-off pelos representantes da Claro, as dores apresentadas podem ter viés corporativo. A proposta foi construída para ser validada de fora para dentro partindo de pesquisa com usuários antes de assumir soluções.

2. A Solução: ClaroIntelligence

O ClaroIntelligence inverte o paradigma padrão de CX em telecom: em vez de forçar o cliente a aprender a linguagem e os limites de cada canal, a empresa aprende o contexto, o perfil e o histórico do cliente e o acompanha onde ele estiver.

A solução não substitui nenhum canal existente nem exige reestruturação organizacional. Opera como middleware inteligente, adicionando três capacidades ausentes no ecossistema atual:

Camada 1 — ClaroMemory: O cliente nunca começa do zero

Cada interação do cliente é armazenada não como log técnico, mas como memória semântica com embeddings vetoriais. O LLM processa o que foi dito, o que foi resolvido, o que ficou pendente e o estado emocional do último contato e disponibiliza esse contexto em qualquer canal subsequente.

Na prática, isso significa:

- Cliente que começou uma reclamação no site e migrou para o WhatsApp não precisa repetir o relato
- Sistema que reconhece 'você estava com problema de conexão semana passada, está tudo bem?'
- Contexto que viaja com o cliente entre WhatsApp, app e site

Tecnologias: LLM (GPT-4 / Claude API), Vector Database (Pinecone ou Weaviate), Unified Customer ID, Apache Kafka para streaming de eventos.

Camada 2 — Persona Engine: A interface se adapta ao cliente

O LLM não apenas entende a intenção, construindo silenciosamente um perfil comportamental do cliente ao longo das interações: nível de literacia digital, preferência de canal, horário de engajamento e estilo linguístico. Com base nisso, adapta tom, vocabulário e complexidade da resposta em tempo real.

A Claro tem clientes que vão de early adopters digitais a usuários de 60+ anos que nunca usaram interface conversacional digital. Uma linguagem única e um fluxo único não servem a ambos. A Persona Engine torna isso transparente sem que nenhum usuário perceba a diferença.

Tecnologias: NLP comportamental, A/B testing por segmento, adaptive dialogue manager, feedback loop contínuo.

Camada 3 — ClaroSense: Agir antes da frustração virar churn

Esta é a camada mais inovadora da proposta. O mercado de CX mede satisfação depois NPS e CSAT chegam quando o cliente já saiu. O ClaroSense detecta sinais de atrito durante a conversa e age proativamente antes do abandono.

Sinais monitorados em tempo real:

- Respostas monossilábicas após perguntas que deveriam gerar engajamento
- Repetição da mesma pergunta após resposta recebida (indica que não foi resolvida)
- Mudança abrupta de canal (indica insatisfação com o canal atual)
- Silêncio prolongado após uma resposta crítica

Ao detectar risco de abandono, o sistema aciona proativamente: muda de canal, oferece atendimento humano, simplifica o fluxo ou antecipa a solução antes que o cliente ligue para o call center ou reclame no Reclame Aqui.

Tecnologias: Sentiment analysis em tempo real, frustration signal classifier, proactive routing engine, dashboard de atrito por jornada.

3. Arquitetura da Solução

3.1 Princípio arquitetural central

PRINCÍPIO

As três camadas operam como middleware sem substituir nenhum canal nem squad. Cada time continua autônomo, mas os canais passam a compartilhar contexto, identidade e inteligência através de uma camada de orquestração comum.

3.2 Stack técnico por camada

Camada	Componentes	Responsabilidade
ClaroMemory	LLM API + Vector DB + Kafka + API Gateway	Persistência e recuperação de contexto semântico entre canais
Persona Engine	NLP Behavioral + A/B Framework + Dialogue Manager	Adaptação em tempo real da experiência ao perfil do usuário
ClaroSense	Sentiment Model + Frustration Classifier + Routing Engine	Deteção proativa de atrito e acionamento de recuperação
Canais (existentes)	WhatsApp x3, App Minha Claro, Site, Call Center, Chatbots	Permanecem autônomos, consomem a camada via SDK
SDK compartilhado	Python/Node.js + Documentação + Testes	Componente reutilizável para integração de novos canais e squads

3.3 Fluxo de uma interação unificada

1. Cliente inicia contato em qualquer canal (WhatsApp, app, site)
2. API Gateway captura o evento e aciona o Unified Customer ID lookup
3. ClaroMemory recupera o contexto semântico das últimas interações
4. Persona Engine ajusta o perfil de resposta ao usuário identificado
5. LLM gera a resposta com contexto completo
6. ClaroSense monitora sinais de atrito em tempo real
7. Se frustração detectada: roteamento proativo para canal ou atendente mais adequado
8. Interação é armazenada como nova memória semântica para futuros contatos

4. Roadmap Incremental

A implementação segue o critério de priorização apresentado no kick-off pela Claro: complexidade técnica × valor para o usuário × valor para o negócio. Cada sprint entrega valor independente — se o alvo mudar, a arquitetura absorve sem reescrever tudo.

Sprint 1 — Fundação (Meses 3–4)

Objetivo: provar que o conceito funciona em escala reduzida e estabelecer as métricas baseline.

Entregas	Métricas de Sucesso
- Definição e implementação do Unified Customer ID - Mapeamento das top 5 jornadas por volume e CES negativo - Protótipo do ClaroMemory em 1 canal (WhatsApp atendimento) - Pesquisa qualitativa com usuários (mín. 10 entrevistas) - Dashboard de métricas baseline (FCR e CES pré-implementação)	- Taxa de resolução no primeiro contato (FCR) baseline - CES médio por jornada mapeada % de clientes que repetem informações ao trocar de canal - Volume de transbordo para call center por jornada

Sprint 2 — Inteligência (Meses 5–6)

Objetivo: escalar o aprendizado do Sprint 1 e introduzir adaptação e detecção proativa.

Entregas	Métricas de Sucesso
- Lançamento do Persona Engine nas 2 jornadas piloto - Treinamento do modelo de frustration signals (ClaroSense v1) - Integração do ClaroSense no fluxo de atendimento - Expansão do ClaroMemory para app + site - Dashboard atualizado com dados de atrito por jornada	- Redução de FCR vs baseline do Sprint 1 - CES pós-implementação nas 2 jornadas piloto - Taxa de intervenção proativa do ClaroSense - Redução de transbordo para call center nas jornadas piloto

Sprint 3 — Escala e Governance (Meses 7–8)

Objetivo: generalizar a solução, reduzir retrabalho entre squads e documentar o impacto financeiro.

Entregas	Métricas de Sucesso
• Expansão para todas as jornadas mapeadas no Sprint 1 • SDK compartilhado documentado e disponível para squads • Modelo de maturidade de canais com score por squad • Cálculo de ROI e impacto financeiro estimado • Visão de longo prazo (12–24 meses) apresentada à liderança	• Redução total de transbordo para call center vs baseline • CES médio geral (todos os canais integrados) • Nº de squads que adotaram o SDK • Estimativa de ROI com base em custo de call center evitado

5. Métricas e Como Medir o Sucesso

5.1 Métricas primárias

Métrica	Sigla	O que mede	Camada responsável
Customer Effort Score	CES	Quanto esforço o cliente precisou fazer para resolver sua necessidade em cada jornada	ClaroMemory + ClaroSense
First Contact Resolution	FCR	% de problemas resolvidos no primeiro contato, sem transbordo ou retorno	ClaroMemory
Taxa de transbordo	—	% de interações digitais que resultaram em ligação para o call center	ClaroSense
Taxa de intervenção proativa	—	% de iminências de abandono detectadas e tratadas pelo ClaroSense antes do abandono	ClaroSense
Adoção do SDK	—	Nº de squads que integraram os componentes compartilhados	Todos

5.2 Meta de impacto estimado

Com base em benchmarks de mercado de implementações similares de CX com IA em operadoras de telecom:

Indicador	Baseline (pré-implementação)	Meta (pós-Sprint 3)
Repetição de informação ao trocar de canal	Alta (sem medição atual)	Redução de 60–70%
Taxa de transbordo para call center	Referência atual da Claro	Redução de 30–40%
CES médio nas jornadas piloto	A medir no Sprint 1	Melhora de 20–30 pontos
Time-to-market de novas integrações	Semanas (por squad)	Redução de 50% via SDK

NOTA METODOLÓGICA

Os números acima são estimativas baseadas em benchmarks de mercado e devem ser calibrados com os dados reais da Claro no Sprint 1. A proposta prioriza a construção de um baseline confiável antes de qualquer compromisso com metas absolutas.

6. Argumentação de Negócio

6.1 Por que agir agora

O custo da inação aumenta exponencialmente com o tempo. Cada jornada quebrada que chega ao call center tem um custo direto estimado entre R\$ 8 e R\$ 25 por ligação (benchmark de telecom brasileiro). Com o volume da Claro, mesmo uma redução de 1% no transbordo representa dezenas de milhões de reais por ano.

Além do custo operacional, há o custo estratégico: nenhuma operadora brasileira oferece hoje experiência conversacional com memória persistente e adaptação de perfil. A janela de diferenciação competitiva existe agora e tende a se fechar conforme o mercado amadurece.

6.2 Por que esta solução e não as alternativas

Abordagem	Limitação	ClaroIntelligence vs.
Chatbot unificado único	Exige desativar canais existentes, desestrutura squads, alto risco de adoção.	Preserva todos os canais; adiciona inteligência sem substituir nada.
Redesign de UX por canal	Resolve o sintoma visual, mas não a fragmentação de contexto e dados.	Resolve a causa raiz: contexto isolado entre sistemas.
CRM melhorado	Armazena histórico, mas não age em tempo real nem adapta a experiência.	Memória semântica ativa + adaptação + detecção proativa.
Unificação organizacional de squads	Processo longo, político, custoso e não resolve o problema técnico.	Solução técnica que viabiliza colaboração sem reorganização.

6.3 O risco do viés corporativo

PONTO CRÍTICO	<i>O Henrique e o Rafa alertaram explicitamente: as dores apresentadas podem ter viés corporativo. A proposta foi desenhada para partir de fora para dentro — pesquisa com usuários reais antes de assumir que o problema interno se traduz diretamente em dor do cliente. Isso diferencia uma proposta de consultoria real de uma que apenas eco-a o que o cliente já disse.</i>
---------------	---

Por isso, o Sprint 1 começa obrigatoriamente com pesquisa qualitativa com usuários (mínimo 10 entrevistas) antes de qualquer desenvolvimento. Apenas após validação externa da dor, a priorização de investimento é confirmada.

6.4 Priorização de investimento

O critério de priorização das jornadas segue a trinca solicitada no kick-off:

- Complexidade técnica: o quanto é difícil de implementar com o stack atual
- Valor para o usuário: o quanto reduz o esforço do cliente naquela jornada
- Valor para o negócio: o quanto reduz custo operacional ou aumenta receita

As jornadas candidatas ao Sprint 1 (a confirmar com pesquisa) são: segunda via de fatura, suporte técnico de conexão, upgrade de plano e contratação de novo produto. São as de maior volume e, historicamente, as que mais geram transbordo para o call center.

7. Diferencial Competitivo da Proposta

Em um challenge com múltiplos grupos, a diferenciação importa tanto quanto a qualidade técnica. Os pontos abaixo demonstram porque o ClaroIntelligence vai além do que a maioria das propostas entregará:

Não é 'chatbot unificado'

A proposta mais comum será juntar tudo em um canal com um bot. O ClaroIntelligence faz o oposto: preserva a autonomia dos times e dos canais, adiciona inteligência como camada. É mais realista para uma empresa do porte da Claro e mais difícil de copiar.

Age antes — não depois — da insatisfação

O ClaroSense inverte o paradigma de CX. Medir NPS depois que o cliente foi embora é tarde. Detectar e agir durante a conversa é a fronteira atual do que se implementa em produção. Nenhuma telecom brasileira faz isso hoje em escala.

Memória semântica, não log técnico

O conceito de Vector Database + LLM para memória conversacional persistente está na fronteira do que se aplica em produção agora. Poucos grupos vão conhecer ou saber articular isso com precisão técnica e narrativa de negócio ao mesmo tempo.

Responde exatamente o que a banca pediu

Viabilidade técnica, priorização de investimento, estratégia incremental e ROI mensurável foram pedidos explicitamente no kick-off. Este documento responde cada um com clareza executiva.

RESPOSTA PARA A BANCA

Quando perguntarem 'como vocês priorizariam?': começamos pela jornada de maior volume com maior CES negativo, implementamos ClaroMemory como fundação, medimos FCR antes e depois — e só escalamos o que provamos. Isso é pensamento de produto, não de projeto.

8. Considerações Finais

O ClaroIntelligence não é uma solução mágica. É uma proposta estruturada, incremental e mensurável para um problema real e caro que a Claro enfrenta.

O que diferencia esta proposta não é a sofisticação tecnológica em si, mas a combinação de: (1) diagnóstico preciso da causa raiz, não apenas dos sintomas; (2) arquitetura que respeita a realidade organizacional da empresa; (3) estratégia incremental que entrega valor a cada sprint; e (4) métricas concretas que permitem cobrar resultado.

Como Rafa e Henrique disseram no kick-off: a pergunta central não é 'como a gente junta tudo' e sim 'como a gente viabiliza que diferentes iniciativas contribuam entre si, de modo que na ponta final, para o cliente, a gente seja uma só interface'. O ClaroIntelligence é a resposta para essa pergunta.